

**Aula Única - Diego
Carvalho, Renato da
Costa**

*DataPrev - Inteligência Artificial - 2026
(Pós-Edital)*

Autor:
**Diego Carvalho, Renato da Costa,
Equipe Informática e TI**

09 de Julho de 2026

Índice

1) Noções de Inteligência Artificial - Teoria	3
2) Noções de Inteligência Artificial - Questões Comentadas - FGV	33
3) Noções de Inteligência Artificial - Lista de Questões - FGV	50
4) Noções de Machine Learning - Teoria	60
5) Noções de Machine Learning - Questões Comentadas - MULTIBANCAS	67
6) Noções de Machine Learning - Lista de Questões - MULTIBANCAS	79

Sumário

Orientações de Estudo	2
Inteligência Artificial	5
Conceitos Básicos.....	5
Ontologias.....	8
Tipos de IA	9
Quanto à Natureza da Inteligência.....	9
Quanto ao Grau de Generalidade.....	11
Riscos e Desafios	11
IA Generativa.....	13
Conceitos Básicos.....	13
Características Fundamentais	14
Principais Modelos	15
Arquiteturas de Treinamento	20
Agentes de IA	22
Sistemas Conversacionais e Assistentes.....	24
Engenharia de Prompt.....	27

ORIENTAÇÕES DE ESTUDO

A aula aborda a Inteligência Artificial (IA), um tema que migrou da ficção científica para a realidade administrativa e, consequentemente, para os editais de concurso. O foco deste material não é formar programadores, mas sim servidores capazes de entender o que é a tecnologia, como ela impacta o serviço público e, principalmente, quais são seus limites éticos e legais. O estudo segue uma lógica de alfabetização em inteligência artificial – partimos das definições, passamos pelos riscos (o ponto mais sensível para o Estado) e chegamos às ferramentas práticas (como o ChatGPT).

Vamos passar por cada tópico e entender – um por um – do que se trata, porque ele foi colocado em aula e vamos exibir uma estratégia de estudo simplificada para aqueles alunos que não possuam tempo suficiente para se aprofundar em cada ponto da aula e desejam fazer um estudado mais otimizado em relação ao custo/benefício, mesmo que deixem de cobrir todos os assuntos. Vejamos:

Conceitos Básicos de Inteligência Artificial

Esse tópico define o que é IA (simulação de processos de inteligência humana), sua história (Teste de Turing) e seus subcampos (Machine Learning, Deep Learning). Trata-se da fundação – você não conseguirá entender "IA Generativa" sem entender antes que ela é um subcampo do "Deep Learning", que por sua vez é subcampo de "Machine Learning".

Os pontos de atenção são a diferenciação entre Machine Learning (aprendizado com dados) e Deep Learning (redes neurais profundas) e a compreensão do Teste de Turing (capacidade de imitar humano). Caso tenha que deixar algo de lado, ignore os detalhes históricos (que são raramente cobrados) e faça uma leitura mais vertical.

Ontologias

Esse tópico trata da representação formal do conhecimento (conceitos e relações) para que computadores possam processá-lo. Ele explica como a máquina "organiza" o conhecimento antes de processá-lo.

O único ponto de atenção é a memorização da definição de ontologia. Caso tenha que deixar algo de lado, ignore, pode pular esse tópico integralmente porque sua incidência em prova é baixíssima e ele não é fundamental para explicar os tópicos seguintes.

Tipos de IA

Esse tópico trata da classificação em IA em Fraca (tarefa específica, sem consciência) e Forte (consciência, teórica); e também da classificação em Discriminativa (classifica) vs. Generativa (cria). As bancas gostam de "pegadinhas" conceituais. Antes de estudar o ChatGPT, você precisa saber que ele é uma IA Fraca (não tem consciência), apesar de parecer esperto.

Os pontos de atenção são a tabela comparativa entre IA Fraca e IA Forte e a diferença conceitual entre Discriminativa (separa dados) e Generativa (cria dados). Caso tenha que deixar algo de lado, ignorem os conceitos de ANI, AGI e ASI porque possuem uma baixíssima incidência em prova.

Riscos e Desafios

Este tópico aborda os perigos inerentes ao uso da IA, incluindo viés algorítmico, desinformação (fake news), violação de direitos autorais e alucinações. Estamos estudando isso logo no início porque, para o serviço público, a legalidade e a ética são tão importantes quanto a eficiência tecnológica. É fundamental entender que a IA não é neutra e pode reproduzir preconceitos.

Os pontos de atenção máxima são o conceito de Viés Algorítmico (a IA discriminando com base em dados de treino ruins), o fenômeno da Alucinação (inventar dados com confiança) e os princípios da Matriz FAT (Fairness/Justiça, Accountability/Responsabilidade, Transparency/Transparência). Recomendo não pular este tópico – ele é o de maior incidência e relevância transversal. Se precisar economizar tempo, foque apenas nas definições de viés e alucinação, ignorando detalhes filosóficos mais profundos.

IA Generativa

Aqui definimos o coração da "hype" atual: sistemas que criam conteúdo novo (texto, imagem, código) em vez de apenas classificar dados existentes. Estudamos isso para diferenciar ferramentas modernas (como o ChatGPT) de softwares antigos. É a base para entender como a máquina "cria".

Os pontos de atenção são a definição básica: IA Generativa cria novos dados a partir de padrões aprendidos (ao contrário da discriminativa que apenas rotula). As bancas cobram se você sabe que ela gera conteúdo inédito e não apenas reproduz cópias exatas. Caso tenha que deixar algo de lado, ignore os detalhes matemáticos sobre "distribuição de probabilidade conjunta", focando apenas no conceito funcional de criação.

Principais Modelos (LLMs e Outros)

Este tópico explora os Grandes Modelos de Linguagem (LLMs) como o GPT. Estudamos isso para entender como o texto é gerado (previsão de próxima palavra/token) e não achar que a máquina "pensa". Também aborda a diferença técnica entre modelos que geram texto, imagem ou áudio.

O ponto de atenção crítico é o conceito de LLM (Large Language Model) e Tokenização. Você deve saber que eles são treinados em grandes volumes de texto para prever a próxima parte da frase. Caso tenha que deixar algo de lado, ignore os "Modelos Generativos Não-Textuais" (áudio e vídeo específicos) e detalhes sobre "Espaço Latente" (Latent Space), pois a cobrança é massiva em cima de modelos de texto (LLMs).

Arquiteturas de Treinamento

Aqui entramos na "casa de máquinas": Redes Neurais, GANs (Redes Adversárias) e Transformers. Estudamos isso para saber a estrutura técnica que permite a IA funcionar. É um tópico mais técnico e "chato", mas necessário para questões específicas.

Os pontos de atenção são dois conceitos específicos: GANs (Redes Adversárias Generativas), onde uma rede cria e a outra julga (jogo de gato e rato), e Transformers, que usam o mecanismo de "atenção" para entender contexto em textos longos. Caso tenha que deixar algo de lado, pode ignorar o funcionamento detalhado de CNNs (convolucionais) e RNNs (recorrentes), focando apenas na definição de GAN e Transformer.

Agentes de IA

Trata de sistemas que percebem o ambiente através de sensores e agem através de atuadores para atingir uma meta. Estudamos isso para entender a definição formal e acadêmica de um sistema inteligente autônomo.

O ponto de atenção é o conceito de Agente Racional (aquele que toma a melhor decisão possível para maximizar o desempenho). Caso tenha que deixar algo de lado, ignore a classificação detalhada dos tipos de agentes (reativo simples, baseado em utilidade, etc) se estiver com pouco tempo, pois a incidência é menor que a de tópicos como Ética ou Prompts.

Sistemas Conversacionais e Engenharia de Prompt


Este tópico ensina como interagir com a IA. Define o que é um "Prompt" e as técnicas para obter melhores respostas (Zero-shot, Few-shot, Chain-of-Thought). Estudamos isso porque é a habilidade prática que será exigida do servidor no uso da ferramenta.

Os pontos de atenção são altíssimos aqui: você precisa dominar bem a definição de Engenharia de Prompt e diferenciar as técnicas: Zero-shot (pedir sem dar exemplo), Few-shot (dar exemplos no pedido) e Chain-of-Thought (pedir para a IA pensar passo a passo). Caso tenha que deixar algo de lado, ignore técnicas muito avançadas ou de nicho (como "Tree of Thoughts" ou "Maieutic Prompting") e foque nas três principais mencionadas.

Principais Aplicações e Ferramentas

Finalizamos com o uso prático: ChatGPT, Copilot, Gemini e aplicações em Direito, Auditoria, etc. Estudamos isso para contextualizar a teoria em "estudos de caso" que as bancas adoram (ex: "um auditor usou IA para...").

Os pontos de atenção são as capacidades e limitações do ChatGPT (ele não é um banco de dados, é um gerador de texto). Caso tenha que deixar algo de lado, ignore as especificações técnicas de ferramentas menores (DeepSeek, Claude) ou comparativos de preços/planos corporativos.



INTELIGÊNCIA ARTIFICIAL

Conceitos Básicos

INCIDÊNCIA EM PROVA: MÉDIA

INTELIGÊNCIA ARTIFICIAL

Trata-se da simulação de processos de inteligência humana por sistemas de computador. Esses processos incluem a aprendizagem (a aquisição de informações e regras para o uso da informação), o raciocínio (usando regras para chegar a conclusões aproximadas ou definitivas) e a autocorreção. A aprendizagem envolve algoritmos que ajustam suas operações com base em novos dados, a fim de melhorar o desempenho, enquanto o raciocínio envolve a aplicação de lógicas para resolver problemas específicos ou tomar decisões.

A concepção de máquinas inteligentes remonta à Antiguidade, quando filósofos como Aristóteles buscaram compreender e formalizar o raciocínio humano. Dessa iniciativa surgiu o silogismo, estrutura lógica dedutiva que viria a influenciar, séculos depois, a lógica computacional. Embora naquela época a ideia de máquinas pensantes fosse meramente metafórica, os fundamentos do pensamento lógico já começavam a ser delineados.

O avanço efetivo nesse campo ocorreu no século XIX, com os trabalhos de George Boole e Gottlob Frege, que desenvolveram a lógica simbólica. Essa formalização do raciocínio em termos matemáticos tornou possível a representação precisa do pensamento humano, permitindo que, teoricamente, máquinas pudessem manipular tais estruturas lógicas.

Em 1936, Alan Turing introduziu um marco decisivo ao apresentar a Máquina de Turing, um modelo teórico capaz de executar qualquer operação lógica representável simbolicamente. Essa concepção não apenas fundamentou a criação dos computadores modernos, como também estabeleceu os alicerces da futura Inteligência Artificial. Turing ainda propôs um critério para avaliar se uma máquina poderia simular o comportamento humano em uma conversa – o Teste de Turing.

O termo “Inteligência Artificial” foi oficialmente introduzido em 1956, durante a Conferência de Dartmouth, nos Estados Unidos. O objetivo central era investigar a viabilidade de programar máquinas para pensar, aprender e resolver problemas de modo semelhante ao humano. A partir desse ponto, a IA passou a constituir um campo específico da ciência da computação, orientado pelo ideal de reproduzir, por meios artificiais, as capacidades cognitivas humanas.

Nas décadas de 1950 e 1960, surgiram os primeiros programas reconhecidos como tentativas iniciais de Inteligência Artificial. O Logic Theorist (1956) demonstrava capacidade de provar teoremas matemáticos, enquanto o ELIZA (1966) simulava uma conversa com um psicoterapeuta, utilizando estruturas simples de linguagem. Essas iniciativas demonstraram o potencial da IA, mas também evidenciaram as limitações tecnológicas da época.

Nos anos 1970, a área enfrentou sua primeira grande crise, conhecida como o “Inverno da IA”. Os computadores eram lentos e caros, e os modelos desenvolvidos mostraram-se limitados, o que levou à redução de investimentos e ao desânimo generalizado. Ainda assim, pesquisas pontuais continuaram, sobretudo em campos como o aprendizado simbólico e os sistemas especialistas.

A década de 1980 marcou uma retomada, com destaque para os sistemas especialistas. Esses programas operavam com base em regras fornecidas por especialistas humanos, sendo eficazes em domínios específicos. O MYCIN, por exemplo, auxiliava no diagnóstico de infecções bacterianas. No entanto, a necessidade de codificação manual do conhecimento limitava a escalabilidade dessas soluções.

Nos anos 1990 e 2000, houve uma mudança paradigmática com a ascensão do Machine Learning. Abandonando a abordagem baseada em regras fixas, os sistemas passaram a aprender a partir de grandes volumes de dados. O desenvolvimento de modelos estatísticos e probabilísticos permitiu que as máquinas identificassem padrões sem instruções explícitas. A vitória do Deep Blue, da IBM, sobre Garry Kasparov, em 1997, simbolizou o avanço da IA em tarefas cognitivamente complexas, mesmo que ainda com base em força computacional bruta.

A popularização da internet e a explosão na geração de dados impulsionaram, a partir dos anos 2010, o avanço do Deep Learning. Redes neurais com múltiplas camadas passaram a reconhecer padrões sofisticados em imagens, sons e textos. O marco inicial dessa fase foi o sucesso do modelo AlexNet em 2012, que revolucionou o reconhecimento de imagens e consolidou o uso de redes neurais profundas em diversas aplicações.

A partir de 2018, o desenvolvimento de modelos generativos, como o GPT (Generative Pre-trained Transformer), representou novo salto tecnológico. Esses modelos demonstraram a capacidade de gerar conteúdos originais com alto grau de coerência, abrangendo texto, imagem, código e música. Com o lançamento do ChatGPT em 2022, seguido pelos modelos GPT-4 e GPT-5, a IA passou a integrar de forma ampla o cotidiano de indivíduos e organizações.

Atualmente, a Inteligência Artificial constitui um campo consolidado da ciência da computação, voltado à criação de sistemas capazes de executar tarefas antes restritas à cognição humana. Entre seus principais subcampos, destacam-se o Aprendizado de Máquina, o Processamento de Linguagem Natural, a Visão Computacional, o Raciocínio Lógico, o Planejamento e os modelos generativos e interativos.

Com essa expansão, crescem também as preocupações relacionadas ao uso responsável da tecnologia. Questões como viés algorítmico, privacidade de dados, transparência e impactos socioeconômicos tornaram-se centrais. Assim, o desafio contemporâneo não se limita à criação de máquinas inteligentes, mas inclui a garantia de que essa inteligência seja aplicada de forma ética, segura e socialmente benéfica.

Ainda nesse contexto, nós temos os Sistemas de IA, que são programas ou conjuntos de tecnologias projetados para simular a inteligência humana em tarefas como percepção, raciocínio, aprendizado, tomada de decisão e resolução de problemas. Em outras palavras, são sistemas capazes de "pensar" ou "agir" de forma inteligente, mesmo que não estejam "conscientes" como nós (a tendência de atribuir características humanas a objetos/máquinas se chama Antropomorfismo). Vejamos suas características:

CARACTERÍSTICAS	DESCRIÇÃO
APRENDIZADO	São capazes de aprender com dados (machine learning) e melhorar ao longo do tempo.
ADAPTAÇÃO	Ajustam seus comportamentos com base em novas informações ou contextos.
AUTONOMIA	Podem executar ações e tomar decisões sem intervenção humana direta.
RACIOCÍNIO	Podem analisar dados, identificar padrões e chegar a conclusões.
INTERAÇÃO	Compreendem e interagem com humanos por meio de linguagem natural, imagens ou sensores.

Vejamos abaixo diversos exemplos de Sistemas de Inteligência Artificial:

APLICAÇÃO	COMO FUNCIONA	BENEFÍCIOS
-----------	---------------	------------

FILTROS DE SPAM NO E-MAIL	Usam algoritmos de aprendizado de máquina e PLN para analisar conteúdo, remetente, frequência e reputação, identificando padrões que permitem classificar automaticamente mensagens como spam ou legítimas.	Reduz golpes e spam, economiza tempo do usuário e aumenta a segurança no uso do e-mail.
RECOMENDAÇÕES AUTOMÁTICAS DE VÍDEO E MÚSICA	Analisa histórico de consumo, preferências explícitas e padrões comportamentais de usuários semelhantes para sugerir conteúdos personalizados por meio de sistemas de recomendação baseados em IA.	Aumentam engajamento, satisfação do usuário e tempo de permanência nas plataformas de streaming.
ASSISTENTES DE VOZ	Combinam reconhecimento automático de fala e processamento de linguagem natural para interpretar comandos, executar ações solicitadas e aprender com interações contínuas do usuário ao longo do tempo.	Facilitam tarefas diárias, ampliam acessibilidade e permitem automação prática por comandos de voz.
CHATBOTS DE ATENDIMENTO	Utilizam modelos de linguagem treinados para compreender perguntas, manter contexto e gerar respostas naturais, atuando em sites e aplicativos, com suporte a texto e, em alguns casos, voz e imagem.	Agilizam o atendimento, reduzem custos operacionais e oferecem suporte contínuo em larga escala.
VEÍCULOS AUTÔNOMOS	Integram sensores, câmeras, radares e algoritmos de visão computacional e decisão para interpretar o ambiente, planejar rotas e conduzir o veículo sem intervenção humana constante.	Prometem maior segurança viária, menos acidentes e mobilidade mais eficiente e autônoma.
DIAGNÓSTICO MÉDICO	Processam exames de imagem, dados laboratoriais e históricos clínicos usando modelos de IA para identificar padrões e auxiliar médicos na detecção precoce de doenças e anomalias.	Aumentam precisão diagnóstica, agilizam análises e apoiam estratégias de medicina preventiva.
DETECÇÃO DE FRAUDES FINANCEIRAS	Analisa grandes volumes de transações em tempo real, identificando padrões anômalos e comportamentos suspeitos por meio de modelos de aprendizado de máquina treinados com dados históricos.	Reduzem perdas financeiras, fortalecem a segurança e aumentam a confiança em sistemas bancários.
TRADUÇÃO AUTOMÁTICA	Utilizam modelos de processamento de linguagem natural treinados em múltiplos idiomas para converter textos entre línguas, preservando significado, contexto e fluidez das frases.	Facilitam comunicação global e ampliam acesso a conteúdos em diferentes idiomas.
RECONHECIMENTO FACIAL E DE IMAGEM	Empregam algoritmos de visão computacional para identificar rostos, objetos e cenários em imagens ou vídeos, comparando padrões visuais com bases de dados treinadas.	Aplicações em segurança, autenticação digital e organização automática de imagens.

Por fim, a tabela seguinte apresenta diversos subcampos da inteligência artificial, tais como: processamento de linguagem natural, redes neurais, aprendizado de máquina, entre outros.

SUBCAMPOS	DESCRIÇÃO
PROCESSAMENTO DE LINGUAGEM NATURAL	Foca no desenvolvimento de sistemas capazes de entender e gerar linguagem humana. Isso inclui tradução automática, análise de sentimentos, reconhecimento de fala e chatbots. PLN permite que computadores interpretem, respondam e utilizem a linguagem humana de maneira significativa.
MACHINE LEARNING	É o estudo de algoritmos que melhoram automaticamente através da experiência. Utiliza técnicas estatísticas para dar aos computadores a capacidade de "aprender" com dados, permitindo-lhes identificar padrões e tomar decisões com mínima intervenção humana.
ROBÓTICA	Combina inteligência artificial com engenharia mecânica e elétrica para projetar e construir robôs capazes de realizar tarefas que exigem interação física com o mundo real. A IA é usada para dar aos robôs a capacidade de perceber, compreender e agir em seu ambiente.

INTELIGÊNCIA ARTIFICIAL GENERATIVA	Envolve a criação de conteúdo novo e original, como texto, imagens, música e vídeo, através de modelos de IA. Usa técnicas como Redes Generativas Adversariais (GANs) para produzir conteúdo que é semelhante, mas não idêntico, ao que eles foram treinados para imitar.
REDES NEURAIS E DEEP LEARNING	Redes neurais são sistemas inspirados no cérebro humano, projetados para reconhecer padrões de maneira semelhante às conexões neurais do cérebro. Deep learning é um subcampo que utiliza redes neurais profundas com muitas camadas para aprender representações de dados complexas.
VISÃO COMPUTACIONAL	Refere-se à capacidade de computadores para identificar, processar e interpretar informações visuais do mundo, semelhante à visão humana. Isso inclui reconhecimento de objetos, rastreamento de movimentos e análise de cenas. É amplamente aplicado em segurança, veículos autônomos, entre outros.

Ontologias

INCIDÊNCIA EM PROVA: MÉDIA

ONTOLOGIA

Representação formal e estruturada do conhecimento de um domínio, que define conceitos, categorias, propriedades e relações entre entidades, estabelecendo um significado compartilhado que pode ser interpretado por humanos e processado por sistemas computacionais, permitindo organização semântica, inferência lógica, interoperabilidade de dados e suporte ao raciocínio em aplicações de Ciência de Dados e Inteligência Artificial.


A Ontologia é uma forma estruturada e formal de representar o conhecimento de um domínio. Ela define conceitos, categorias, propriedades e relações entre entidades, criando um vocabulário comum que pode ser entendido tanto por humanos quanto por máquinas. Em essência, uma ontologia descreve o que existe em um domínio e como essas coisas se relacionam.

Do ponto de vista computacional, a ontologia vai além de simples listas de termos ou esquemas de dados. Enquanto um banco de dados define como os dados são armazenados, a ontologia define o significado desses dados. Isso inclui hierarquias (por exemplo, "todo professor é uma pessoa"), relações semânticas ("um cliente realiza uma compra") e restrições lógicas que ajudam a garantir consistência no conhecimento representado.

Na Ciência de Dados, ontologias são especialmente úteis para integrar dados de fontes heterogêneas. Em projetos reais, dados costumam vir de sistemas diferentes, com nomes distintos para conceitos semelhantes. A ontologia atua como uma camada semântica intermediária, permitindo alinhar, reconciliar e interpretar corretamente esses dados, reduzindo ambiguidades e erros de interpretação.

Em Inteligência Artificial, ontologias desempenham um papel central na chamada IA simbólica e em sistemas baseados em conhecimento. Elas permitem que algoritmos façam inferências lógicas, deduzam novos fatos a partir de regras e relações já definidas e verifiquem inconsistências. Isso é fundamental em sistemas especialistas, agentes inteligentes e aplicações que exigem explicabilidade.

Outro ponto importante é a relação entre ontologias e aprendizado de máquina. Embora modelos estatísticos aprendam padrões a partir de dados, eles geralmente não "entendem" o significado desses padrões. Ontologias podem complementar o machine learning ao fornecer contexto semântico, guiando a seleção de atributos, ajudando na interpretação dos resultados e melhorando a explicabilidade dos modelos, especialmente em ambientes críticos.



Tipos de IA

INCIDÊNCIA EM PROVA: MÉDIA

Quando a gente fala em inteligência artificial, temos como classificá-las de acordo com diversos critérios como natureza da inteligência e nível de compreensão real do sistema; ou em grau de generalidade e capacidade cognitiva da inteligência artificial em relação à inteligência humana. Vejamos em detalhes a seguir essas classificações:

Quanto à Natureza da Inteligência


A distinção entre Inteligência Artificial (IA) Forte e IA Fraca é uma das mais antigas e controversas no campo da tecnologia. Trata-se de duas concepções distintas sobre o que constitui “inteligência” em máquinas. A IA Fraca, ou IA Estreita, corresponde aos sistemas atualmente existentes e amplamente utilizados. São projetados para executar tarefas específicas com alta eficiência, mas sem qualquer forma de consciência, compreensão ou raciocínio generalizado.

Exemplos incluem assistentes virtuais, sistemas de recomendação, algoritmos de reconhecimento de imagem e modelos de linguagem. Esses sistemas operam com base em estatísticas e aprendizado de máquina, sendo capazes de identificar padrões e gerar respostas, mas sem entender o contexto como um ser humano.

Já a IA Forte envolve a criação de sistemas com consciência própria, compreensão real, capacidade de raciocínio abstrato, criatividade e julgamento moral. Esse tipo de inteligência seria comparável – ou superior – à inteligência humana, sendo capaz de executar qualquer tarefa cognitiva, inclusive transferir conhecimentos adquiridos em um contexto para resolver problemas em outro, algo que as IAs atuais não conseguem realizar. Ela, portanto, representa uma forma de inteligência geral artificial, ainda inexistente.

A principal diferença entre ambas está no escopo: enquanto a IA Fraca é limitada a domínios específicos, a IA Forte teria uma capacidade cognitiva abrangente e autônoma. O desenvolvimento de uma IA Forte implicaria desafios significativos não apenas tecnológicos, mas também filosóficos, éticos e jurídicos. Questões como direitos para máquinas conscientes, responsabilidade por suas ações e os limites de sua autonomia são amplamente debatidas, mas permanecem sem respostas conclusivas.

Atualmente, o foco da indústria permanece na IA Fraca, com avanços notáveis em áreas como aprendizado profundo, aprendizado de máquina e processamento de linguagem natural, aplicados em soluções práticas como chatbots, veículos autônomos e sistemas médicos. Contudo, a concretização da IA Forte exigirá avanços substanciais não só em tecnologia, mas também em disciplinas como neurociência, psicologia cognitiva e filosofia da mente, pois envolve a criação de uma forma artificial de consciência. Dessa forma, a IA Fraca representa a realidade presente, enquanto a IA Forte ainda se configura como um desafio futuro. Vejamos suas principais características:




CARACTERÍSTICAS	IA FRACA	IA FORTE
DEFINIÇÃO	Sistema projetado para executar tarefas específicas com eficiência, sem compreensão ou consciência do que faz.	Inteligência artificial com capacidade de raciocínio geral e autoconsciência, capaz de entender, sentir e aprender amplamente.
EXEMPLOS	ChatGPT, Alexa, Siri, tradutores automáticos, reconhecimento facial, filtros de spam e algoritmos de recomendação.	Uma IA hipotética com raciocínio autônomo, como HAL 9000 (ficção) ou modelos futuros de inteligência geral (AGI).
CAPACIDADE DE APRENDIZADO	Aprende a partir de dados limitados e padrões específicos, sem transferir o aprendizado para novos contextos.	Aprende de forma contínua e autônoma, generalizando conhecimentos entre diferentes domínios e experiências.
CONSCIÊNCIA	Não possui autoconsciência nem entendimento genuíno; responde com base em padrões probabilísticos.	Possui (ou possuiria) consciência própria, senso de identidade e capacidade de reflexão sobre suas ações e intenções.
TOMADA DE DECISÃO	Baseada em regras e dados predefinidos; depende de instruções humanas e contexto de programação.	Toma decisões complexas de forma independente, avaliando consequências e valores morais de suas escolhas.

STATUS ATUAL	É o tipo de IA que realmente existe hoje e está presente em praticamente todas as aplicações comerciais e científicas.	Ainda teórica; não há comprovação técnica ou científica de sua existência em sistemas computacionais reais.
EXEMPLOS DE APLICAÇÃO	Atendimento automatizado, diagnóstico médico assistido, previsão de demanda, tradução e análise de dados.	Exploração espacial autônoma, governança de sistemas complexos ou robôs conscientes (ainda no campo teórico).
RISCO ÉTICO	Envolve vieses de dados, manipulação de informação e falta de transparência em decisões automatizadas.	Envolve perda de controle humano, dilemas morais, autonomia excessiva e potencial ameaça existencial.

Quanto ao Grau de Generalidade

Essa classificação está relacionada ao nível de escopo, autonoia e competência intelectual que um sistema de inteligência artificial possui para resolver problemas, aprender e se adaptar. Vejamos:

TIPO DE IA	DESCRIÇÃO
ANI (ARTIFICIAL NARROW INTELLIGENCE)	A ANI é a IA voltada para tarefas específicas e bem delimitadas, atuando em um único domínio. Ela não possui compreensão geral nem capacidade ampla de generalização, executando apenas aquilo para o qual foi treinada, como reconhecimento de imagens, tradução automática ou assistentes virtuais.
AGI (ARTIFICIAL GENERAL INTELLIGENCE)	A AGI representa uma IA com capacidade cognitiva geral comparável à humana, capaz de aprender, raciocinar, adaptar-se e transferir conhecimento entre diferentes domínios. Ela resolveria variados tipos de problemas sem treinamento específico para cada tarefa, de forma flexível e autônoma.
ASI (ARTIFICIAL SUPER INTELLIGENCE)	A ASI refere-se a uma inteligência artificial hipotética que ultrapassaria amplamente as capacidades cognitivas humanas em praticamente todos os aspectos, incluindo raciocínio, criatividade e tomada de decisões. Envolve debates éticos profundos, pois seu poder excederia o controle humano.



Riscos e Desafios


INCIDÊNCIA EM PROVA: MÉDIA

A ascensão da Inteligência Artificial Generativa trouxe avanços notáveis na criação de conteúdos, automação de tarefas e inovação em diversos setores, mas também acendeu um alerta global sobre os riscos e desafios associados ao seu uso indiscriminado. Ao mesmo tempo em que essas ferramentas oferecem praticidade e eficiência, elas também levantam questões complexas envolvendo desinformação, violação de direitos autorais, vieses algorítmicos, impacto no mercado de trabalho, uso indevido de dados sensíveis e outros dilemas éticos e sociais.

Compreender esses riscos é essencial para que possamos aproveitar os benefícios da IA sem comprometer valores fundamentais como privacidade, equidade, transparência e segurança.

RISCOS	DESCRIÇÃO
ÉTICA E RESPONSABILIDADE	A Inteligência Artificial Generativa traz grandes oportunidades criativas, mas também exige ética e responsabilidade para evitar abusos como desinformação, deepfakes e reprodução de preconceitos. É essencial que seu desenvolvimento siga normas claras, supervisão humana e princípios FAT – Fairness (justiça), Accountability (responsabilidade) e Transparency (transparência) – garantindo sistemas imparciais, auditáveis e sob controle humano. Assim, a IA só será verdadeiramente avançada quando sua capacidade de criar vier acompanhada do compromisso de respeitar direitos, promover valor social e servir ao bem comum.
DESINFORMAÇÃO (FAKE NEWS)	A IA Generativa revolucionou a criação de conteúdo digital, mas também ampliou o risco de desinformação, permitindo a produção e disseminação em massa de textos, imagens, áudios e vídeos falsos com aparência realista. Deepfakes e conteúdos automatizados podem manipular eleições, fraudar pessoas e afetar reputações, enquanto a falta de rastreabilidade e de leis claras dificulta a responsabilização. Diante disso, propõem-se soluções como marcas d'água digitais, educação midiática, regulamentação específica e reforço da checagem de fatos, unindo esforços técnicos, éticos e sociais para conter o uso indevido dessa tecnologia.
VIOLAÇÃO DE DIREITOS AUTORAIS	Um dos maiores desafios da IA Generativa é a violação de direitos autorais, já que muitos modelos são treinados com obras protegidas – como textos, músicas e imagens – sem consentimento ou compensação aos autores. Isso leva à criação de conteúdos muito semelhantes aos originais, gerando dúvidas sobre autoria, propriedade intelectual e responsabilidade legal. Como as leis atuais pressupõem autoria humana, surge uma lacuna jurídica que enfraquece a proteção dos criadores. Propõem-se soluções como licenciamento prévio, direito de exclusão (opt-out), rastreamento de uso e revisão das normas de copyright, buscando equilibrar inovação tecnológica e respeito aos direitos criativos.
ALUCINAÇÕES/ DESATUALIZAÇÕES	Um dos principais desafios da IA Generativa é o fenômeno das “alucinações”, quando o modelo inventa informações falsas com aparência convincente. Isso ocorre porque ele não entende o conteúdo, apenas prevê probabilisticamente a sequência de palavras mais provável, podendo gerar dados incorretos, referências inexistentes ou informações desatualizadas. O problema se agrava em contextos que exigem precisão, como pesquisa acadêmica ou jornalismo. Mesmo com ferramentas de busca em tempo real, o risco de erro persiste – por isso, é essencial manter a supervisão humana e a verificação crítica das respostas geradas por IA.
VERIFICAÇÃO HUMANA	A verificação humana em sistemas de Inteligência Artificial é indispensável, especialmente em áreas sensíveis como saúde, justiça e finanças. Por mais eficientes que sejam, os algoritmos ainda cometem erros e precisam de supervisão para garantir decisões éticas e contextualizadas. Essa supervisão pode ocorrer via abordagens como human-in-the-loop (decisão final humana) ou human-on-the-loop (vigilância constante), ambas voltadas a manter o senso crítico e a responsabilidade humana. Em qualquer aplicação, o usuário deve verificar, editar e validar os resultados da IA, assegurando que a tecnologia realmente sirva às pessoas – e não o contrário.
DADOS SENSÍVEIS	A Lei Geral de Proteção de Dados (LGPD) é essencial no contexto da Inteligência Artificial, pois regula o uso de informações pessoais em modelos que dependem de grandes volumes de dados. Ela exige consentimento claro, livre e informado, além de

transparência sobre o uso e a finalidade dos dados, especialmente em decisões automatizadas. Também impõe responsabilidade e prestação de contas às empresas, que devem comprovar conformidade legal, adotar medidas de segurança e evitar vieses ou discriminações algorítmicas. Em suma, a LGPD busca equilibrar inovação com proteção dos direitos e da privacidade das pessoas.



IA Generativa

Conceitos Básicos

INCIDÊNCIA EM PROVA: MÉDIA

INTELIGÊNCIA ARTIFICIAL GENERATIVA


Trata-se de um conjunto de técnicas de inteligência artificial projetadas para criar conteúdo novo e original, que pode variar desde texto, imagens e música até dados sintéticos e muito mais. O objetivo principal desses sistemas é aprender padrões, estilos ou características de conjuntos de dados existentes e, em seguida, gerar novos dados que sejam semelhantes em qualidade e diversidade, mas únicos em conteúdo.

A partir de 2022, a Inteligência Artificial passou por uma transformação significativa com a popularização de modelos generativos como ChatGPT e DALL-E, capazes de criar textos, imagens, músicas, códigos e outros conteúdos criativos. A IA deixou de ser uma tecnologia restrita a especialistas e tornou-se amplamente acessível, consolidando-se como uma ferramenta prática e colaborativa na produção de conteúdos digitais.

A Inteligência Artificial Generativa é um ramo da IA dedicado à criação de conteúdos inéditos. Diferentemente de sistemas tradicionais, voltados à classificação ou análise de dados, esses modelos geram novos textos, imagens, áudios ou vídeos com base em padrões estatísticos aprendidos a partir de grandes volumes de dados humanos. Não se trata de reprodução literal, mas de geração probabilística de novas combinações plausíveis.

Essas capacidades são viabilizadas pelos chamados modelos de base (foundation models), treinados em conjuntos massivos e multimodais de dados, como textos, imagens, sons e vídeos. Seu funcionamento se apoia em distribuições de probabilidade, estimando qual elemento é mais provável de surgir em

sequência – seja uma palavra, um pixel ou uma nota musical – o que permite aplicações como criação de conteúdo, aprimoramento de materiais existentes e automação de tarefas criativas.



O desenvolvimento desses modelos envolve etapas como coleta e preparação de dados, treinamento em larga escala, fine-tuning e alinhamento, seguidas de implantação e inferência em ambientes reais. Embora não possuam consciência ou entendimento humano, sua capacidade de gerar conteúdo original os transforma em agentes criativos colaborativos, ampliando o papel da IA de simples automação para atuação ativa na produção cultural e intelectual.


Características Fundamentais

A IA Generativa está na vanguarda da inovação em Inteligência Artificial, permitindo a criação automática de conteúdo novo e significativo. Vejamos suas características básicas:

CARACTERÍSTICA	DESCRIÇÃO
GERAÇÃO DE CONTEÚDO NOVO	A IA generativa destaca-se pela capacidade de criar conteúdos inéditos, como textos, imagens, sons e códigos, a partir de padrões estatísticos aprendidos no treinamento. Ela não copia dados existentes, mas gera saídas originais, probabilísticas e contextualizadas conforme o prompt fornecido.
APRENDIZADO DE MÁQUINA	Fundamenta-se em técnicas de aprendizado supervisionado, não supervisionado e por reforço para extrair padrões de grandes volumes de dados. Na IA generativa, o pré-treinamento não supervisionado e o reforço para alinhamento comportamental são elementos centrais do processo.
MODELOS DE BASE	Os modelos de base são redes neurais de grande escala treinadas com dados diversos, capazes de generalizar conhecimento. Após o treinamento inicial, podem ser ajustados para múltiplas tarefas, reduzindo custos, tempo de desenvolvimento e a necessidade de treinar modelos do zero.
MULTIMODALIDADE	Caracteriza-se pela capacidade de processar e gerar múltiplos tipos de dados, como texto, imagem, áudio e vídeo, de forma integrada. Isso permite compreender contextos mais ricos e produzir respostas coerentes em diferentes formatos, aproximando a interação da comunicação humana.

ADAPTABILIDADE E VERSATILIDADE

Um único modelo generativo pode executar diversas tarefas a partir de diferentes prompts, ajustando estilo, tom e profundidade conforme o contexto. Essa flexibilidade amplia aplicações e eficiência, mas exige cautela em áreas sensíveis para evitar usos inadequados.



Principais Modelos

Na Inteligência Artificial, distinguem-se duas abordagens fundamentais no processamento e análise de dados: os modelos discriminativos e os modelos generativos. Cada um possui funções distintas e complementares, com aplicações específicas em tarefas de classificação, previsão, geração de conteúdo e personalização de sistemas.

Modelos discriminativos aprendem a distinguir categorias com base em exemplos rotulados. Eles modelam a probabilidade condicional $P(Y|X)$, ou seja, calculam a probabilidade de uma determinada saída Y ocorrer, dado um conjunto de entradas X . São utilizados em tarefas como classificação, detecção e predição, onde o objetivo é identificar com precisão a classe a que pertence determinada entrada.

Entre os exemplos clássicos dessa abordagem estão a regressão logística, as máquinas de vetores de suporte (SVM), redes neurais supervisionadas e modelos como o BERT.

Sistemas de recomendação e mecanismos de busca aplicam, com frequência, modelos discriminativos. Esses sistemas analisam grandes volumes de dados sobre usuários, conteúdos e interações, utilizando métodos como análise de palavras-chave, similaridade entre itens, histórico de cliques e comportamento coletivo para filtrar e sugerir informações relevantes. Enquanto os mecanismos de busca priorizam a correspondência entre consulta e conteúdo, os sistemas de recomendação visam antecipar interesses e promover engajamento, baseando-se em padrões previamente observados.


Em contraste, os modelos generativos buscam compreender e reproduzir a estrutura dos dados. Modelam a distribuição conjunta $P(X,Y)$, o que permite não apenas prever categorias, mas também gerar novas amostras semelhantes aos dados originais. São capazes de criar textos, imagens, sons e vídeos

inéditos com base em padrões aprendidos durante o treinamento. Exemplos notáveis incluem os modelos GPT, DALL·E, Stable Diffusion, GANs e os Variational Autoencoders (VAEs).

Na prática, os modelos discriminativos tendem a apresentar maior precisão e eficiência em tarefas específicas de reconhecimento, sendo limitados àquilo que já observaram. Por outro lado, os modelos generativos, embora mais complexos e suscetíveis a vieses ou imprecisões, oferecem maior flexibilidade e criatividade, viabilizando a geração de novos conteúdos e a simulação de contextos variados.

A diferença essencial entre ambos reside na natureza de seu aprendizado: enquanto os modelos discriminativos reconhecem padrões e delimitam fronteiras entre categorias, os generativos imaginam novas possibilidades a partir desses padrões. Essa distinção é central para compreender o funcionamento e as aplicações da Inteligência Artificial contemporânea.

O futuro da Inteligência Artificial aponta para a integração dessas duas abordagens. Muitos sistemas atuais combinam capacidades discriminativas (analisar, comparar, julgar) com capacidades generativas (criar, simular, expandir). Dessa forma, a IA se torna não apenas capaz de entender o mundo, mas também de criar novas versões dele, o que exige – mais do que nunca – supervisão ética e validação humana sobre tudo o que é produzido.



CARACTERÍSTICA	MODELOS GENERATIVOS	MODELOS DISCRIMINATIVOS
OBJETIVO	Buscam aprender a distribuição de probabilidade dos dados, permitindo gerar novas amostras semelhantes às observadas no treinamento. Após aprender os padrões, o modelo é capaz de criar dados inéditos com características realistas.	Têm como objetivo separar ou classificar dados, aprendendo a fronteira de decisão entre classes. O foco está em identificar a classe correta de uma entrada, sem a necessidade de gerar novos dados.
ABORDAGEM	Modelam explicitamente como os dados são gerados, aprendendo a distribuição conjunta das variáveis. Essa abordagem permite tanto classificar quanto gerar novos exemplos compatíveis com os dados aprendidos.	Modelam diretamente a probabilidade da classe dado o conjunto de entradas, aprendendo relações discriminativas. Não tentam representar como os dados são gerados, apenas como devem ser separados.

EXEMPLOS	Incluem GANs, Autoencoders Variacionais (VAEs) e Modelos de Mistura Gaussiana (GMMs), capazes de gerar imagens, sons ou textos novos, mantendo semelhança estatística com os dados de treinamento.	Incluem algoritmos como Regressão Logística, SVMs e redes neurais tradicionais, amplamente usados em classificação e previsão, onde a saída desejada é uma categoria ou valor específico.
APLICAÇÕES	Usados em geração de conteúdo, como texto, imagem, áudio e vídeo, além de simulação de dados e modelagem de linguagem, quando o objetivo principal é criar novas amostras realistas.	Aplicados em tarefas de reconhecimento e decisão, como classificação de imagens, detecção de spam, diagnósticos médicos e reconhecimento de fala, onde o objetivo é rotular corretamente os dados.
EFICIÊNCIA DE DADOS	Podem ser mais eficientes em cenários com poucos dados, pois aprendem a estrutura completa da distribuição. Isso permite reutilizar o conhecimento aprendido para geração e análise de dados semelhantes.	Geralmente exigem mais dados para atingir alta precisão, mas são mais eficientes em tarefas específicas, pois focam diretamente na previsão ou classificação sem modelar toda a distribuição dos dados.

Modelos de Linguagem

Os Modelos de Linguagem são sistemas de IA generativa projetados para compreender, produzir e manipular linguagem humana. Eles aprendem padrões linguísticos a partir de grandes volumes de texto, capturando relações sintáticas, semânticas e contextuais que permitem gerar frases coerentes e respostas relevantes em diferentes contextos.

Esses modelos operam, em geral, de forma autorregressiva, prevendo o próximo token com base nos anteriores. Para isso, utilizam representações vetoriais como embeddings, organizadas em espaços latentes, e arquiteturas como Transformers, que empregam mecanismos de atenção para manter contexto e coerência em textos longos.

Na prática, os modelos de linguagem são aplicados em tarefas como chatbots, tradução automática, resumo de textos, geração de código e apoio à escrita. Apesar de produzirem respostas convincentes, não possuem compreensão real, operando por meio de cálculos probabilísticos sobre padrões aprendidos nos dados.

Large Language Model (LLM)

INCIDÊNCIA EM PROVA: BAIXA

Os Modelos de Linguagem de Larga Escala (LLMs) são sistemas de IA projetados para compreender e gerar linguagem humana com alto grau de sofisticação. Eles se baseiam na arquitetura Transformer, introduzida em 2017, que revolucionou o processamento de linguagem natural ao permitir o aprendizado de padrões linguísticos a partir da análise de volumes massivos de texto. Durante o treinamento, os LLMs processam bilhões de palavras provenientes de livros, artigos, sites e outras fontes, identificando relações estatísticas entre os termos, o que lhes permite gerar sequências textuais coerentes.

Internamente, esses modelos não operam diretamente com palavras, mas com representações numéricas chamadas embeddings. Cada palavra ou fragmento de palavra é convertido em um vetor de números que ocupa uma posição em um espaço multidimensional. Nesse espaço, termos semanticamente relacionados tendem a ficar próximos, enquanto conceitos distintos ficam mais distantes. Essa organização vetorial permite ao modelo calcular proximidade semântica e estimar quais palavras são mais prováveis de aparecer em determinado contexto.

Antes de serem transformadas em embeddings, as entradas textuais passam por um processo chamado tokenização, no qual o texto é dividido em unidades menores chamadas tokens. Essa tokenização pode ocorrer por diferentes métodos, como o BPE (Byte Pair Encoding), que fragmenta palavras em

subunidades frequentes, permitindo lidar melhor com palavras raras, variações morfológicas e reduzir o vocabulário necessário ao modelo.

Esse espaço multidimensional onde os embeddings são organizados é conhecido como latent space (ou espaço latente). Ele não representa palavras de forma explícita ou literal, mas codifica características abstratas da linguagem, como significado, contexto e relações semânticas. No latent space, ideias semelhantes ocupam regiões próximas, permitindo que o modelo "transite" entre conceitos e produza variações coerentes, mesmo quando o texto gerado não foi visto exatamente daquela forma durante o treinamento.

A arquitetura Transformer utiliza mecanismos de atenção para avaliar, a cada etapa, quais partes do contexto são mais relevantes. O significado, portanto, não está em regras explícitas, mas nas relações entre vetores ao longo do texto. Com base nessas relações, o modelo prevê a próxima palavra de forma probabilística, o que explica sua capacidade de generalizar e executar tarefas variadas, como tradução, resumo, resposta a perguntas, programação e geração de textos em diferentes estilos.

Esse modo de funcionamento é tecnicamente chamado de modelo autorregressivo. Isso significa que o LLM gera o texto token por token, prevendo cada próximo elemento da sequência com base apenas nos tokens anteriores já produzidos ou fornecidos como contexto. A cada nova previsão, o token gerado é incorporado à entrada do modelo, influenciando as previsões seguintes, o que permite a construção progressiva de frases, parágrafos e diálogos completos.

O Mecanismo de Atenção (em inglês, Attention Mechanism) é crucial para manter coerência e consistência em textos longos e conversas prolongadas dentro desse processo autorregressivo. Ele permite que o modelo foque dinamicamente em informações relevantes que apareceram anteriormente, independentemente da distância no texto, superando limitações de modelos mais antigos que perdiam contexto ao longo da sequência. Dessa forma, o LLM consegue retomar referências, manter o fio da conversa e produzir respostas alinhadas ao histórico do diálogo.

Essa versatilidade contrasta com abordagens mais antigas, nas quais modelos eram treinados para funções específicas. Um único LLM pode ser adaptado para múltiplos usos apenas pela mudança do contexto fornecido no prompt, sem alteração de sua estrutura interna. Isso o torna uma ferramenta extremamente flexível em áreas como direito, saúde, educação, comunicação e tecnologia.

O treinamento de LLMs, entretanto, é altamente complexo e custoso, exigindo grande infraestrutura computacional, elevado consumo de energia e curadoria cuidadosa dos dados. Dados enviesados, incorretos ou desatualizados podem se refletir diretamente nas respostas geradas, o que levanta questões importantes sobre ética, transparência e responsabilidade no uso desses modelos.

Atualmente, LLMs já fazem parte do cotidiano por meio de assistentes virtuais, tradutores automáticos, sistemas de atendimento, corretores de texto e ferramentas de apoio à escrita e à programação. Apesar de produzirem respostas fluentes e convincentes, é essencial lembrar que esses modelos não possuem compreensão, consciência ou intenção. Suas saídas resultam de cálculos probabilísticos autorregressivos sobre representações vetoriais, e não de entendimento real do conteúdo.

Os LLMs estão evoluindo rápido, e a expectativa é que se tornem cada vez mais eficientes e acessíveis; mas também cresce a pressão por regulamentação, transparência nos dados utilizados e educação digital para a população. Afinal, uma tecnologia tão poderosa precisa ser acompanhada de responsabilidade, para garantir que beneficie a todos sem causar danos sociais, éticos ou econômicos. Como em toda revolução, o mais importante é entender os riscos e se preparar bem para o que está por vir.

COMO FUNCIONAM OS LLMs (Large Language Models)



Modelos de Linguagem Multimodais

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

Os Modelos de Linguagem Multimodais são sistemas de IA capazes de processar, compreender e gerar informação a partir de múltiplas modalidades simultaneamente, como texto, imagens, áudio, vídeo e, em alguns casos, código. Diferentemente dos modelos tradicionais, que lidam apenas com linguagem escrita, esses modelos integram diferentes formas de dados em uma representação unificada.

Na prática, isso significa que o modelo não trata cada modalidade de forma isolada. Ele aprende relações semânticas entre modalidades, como associar uma descrição textual a uma imagem, interpretar um gráfico a partir de texto ou responder perguntas sobre um vídeo. Essa integração permite uma compreensão mais rica do contexto e da intenção do usuário.

Do ponto de vista técnico, modelos multimodais utilizam representações vetoriais (embeddings) para cada modalidade, que são projetadas para um espaço latente comum. Nesse espaço compartilhado, texto, imagem e áudio podem ser comparados, combinados e transformados uns nos outros, permitindo tarefas como geração de imagens a partir de texto ou descrição textual de imagens.


Arquiteturas baseadas em Transformers multimodais costumam empregar mecanismos de atenção cruzada, nos quais informações de uma modalidade influenciam o processamento da outra. Isso permite, por exemplo, que o modelo foque em partes específicas de uma imagem ao responder uma pergunta textual, mantendo coerência e alinhamento entre os diferentes tipos de entrada.

Esses modelos ampliam significativamente as possibilidades de aplicação da IA, viabilizando assistentes mais naturais, sistemas educacionais interativos, ferramentas de acessibilidade, análise avançada de dados visuais e criação de conteúdo multimídia. Ao aproximar a forma de processamento da IA da maneira como os humanos percebem o mundo, os modelos de linguagem multimodais representam um passo importante na evolução da IA generativa.

Modelos Generativos Não-Textuais

Os Modelos Generativos Não-Textuais são voltados à criação de conteúdos em modalidades diferentes da linguagem escrita, como imagens, áudio, vídeo e sinais. Seu objetivo é aprender a distribuição desses dados para gerar novas amostras visuais ou sonoras realistas. Esses modelos incluem abordagens como GANs, VAEs e Modelos de Difusão, que utilizam estratégias distintas para produzir dados sintéticos.

Enquanto GANs se baseiam em competição entre redes, modelos de difusão geram conteúdo por processos graduais de refinamento a partir de ruído. As aplicações desses modelos abrangem geração de imagens e vídeos, síntese de voz, criação musical, restauração de conteúdo e simulação de dados. Assim como nos modelos de linguagem, os resultados são estatísticos e probabilísticos, mas com impacto crescente em áreas criativas, científicas e industriais.



Arquiteturas de Treinamento

Arquiteturas de Redes Neurais

A arquitetura de redes neurais é a estrutura que define como os neurônios artificiais de um modelo estão organizados e interconectados, especificando o número de camadas, o tipo de cada camada, a forma de conexão entre elas e o fluxo de informação ao longo da rede. Ela determina como dados de entrada são transformados em saídas por meio de operações matemáticas, influenciando diretamente a capacidade do modelo de aprender padrões, generalizar conhecimento e resolver diferentes tipos de problemas.

ARQUITETURA	DESCRIÇÃO
FEED-FORWARD (MLP)	Arquitetura mais básica de rede neural, na qual os dados fluem em uma única direção, da entrada à saída, sem ciclos. Utiliza camadas totalmente conectadas e retropropagação para ajustar pesos, sendo aplicada em classificação, regressão e padrões simples.
CONVOLUCIONAL (CNN)	Projetada para dados em grade, como imagens, utiliza camadas de convolução e pooling para extrair padrões visuais locais, como bordas e formas. Reduz dimensionalidade e aprende hierarquias de características, sendo amplamente usada em visão computacional e reconhecimento de imagens.

RECORRENTE (RNN)	Desenvolvida para dados sequenciais, possui conexões recorrentes que permitem reter informações anteriores, criando uma memória temporal. É aplicada em textos, áudio e séries temporais, com variantes como LSTM e GRU para lidar com dependências longas.
TRANSFORMER	Arquitetura que elimina recorrência e utiliza mecanismos de atenção para processar sequências em paralelo. Consegue capturar dependências de longo alcance com eficiência, sendo a base de modelos modernos de linguagem natural, como GPT e BERT.

ARQUITETURAS DE REDES NEURAIS:

Organização e Fluxo de Informação




Modelos Generativos Clássicos

Modelos generativos clássicos são abordagens de aprendizado de máquina desenvolvidas antes da popularização dos grandes modelos baseados em Transformers, cujo objetivo é aprender a distribuição dos dados para gerar novas amostras semelhantes às observadas no treinamento. Esses modelos, como GANs e VAEs, utilizam estruturas estatísticas ou redes neurais específicas para representar a variabilidade dos dados e possibilitar a criação de conteúdos sintéticos, como imagens, sinais ou sequências, servindo de base conceitual para os avanços posteriores da IA generativa.

Além das GANs e dos VAEs, existem outras classes de modelos generativos clássicos que, embora menos populares no uso cotidiano, são relevantes do ponto de vista teórico e aparecem com frequência como alternativas conceituais. Entre eles estão os modelos baseados em energia (Energy-Based Models), que aprendem uma função de energia para atribuir maior probabilidade a configurações plausíveis dos dados, e os modelos de fluxo normalizador (Normalizing Flows), que utilizam transformações matemáticas invertíveis para mapear distribuições simples em distribuições complexas de dados.

Essas abordagens reforçam que a geração de dados pode ser tratada por diferentes estratégias matemáticas e probabilísticas, cada uma com vantagens e limitações específicas. Embora GANs e VAEs tenham se destacado historicamente, os modelos baseados em energia e em fluxo normalizador ampliam o panorama dos modelos generativos clássicos, ajudando a compreender a diversidade de técnicas que fundamentaram a evolução da IA generativa moderna.

MODELO	DESCRIÇÃO
GAN (REDES ADVERSÁRIAS GENERATIVAS)	Modelo generativo composto por duas redes em competição: a geradora cria dados sintéticos e a discriminadora avalia sua autenticidade. Esse jogo min-max permite gerar amostras realistas, sendo amplamente usado em imagens, deepfakes e arte digital, apesar de desafios como colapso de modo.
VAE (AUTOENCODERS VARIACIONAIS)	Modelo generativo baseado em encoder e decoder que aprende um espaço latente probabilístico. Em vez de codificações determinísticas, modela distribuições contínuas, permitindo gerar novas amostras por interpolação. Oferece maior estabilidade e controle matemático, embora com menor nitidez visual.
MODELOS DE DIFUSÃO	Modelos generativos que aprendem a gerar dados ao reverter gradualmente um processo de adição de ruído. A partir de ruído puro, constroem amostras passo a passo, garantindo alta estabilidade e qualidade. São amplamente usados em geração de imagens, vídeo e áudio, apesar da maior lentidão.



Agentes de IA

INCIDÊNCIA EM PROVA: BAIXA

AGENTE DE INTELIGÊNCIA ARTIFICIAL

Em Inteligência Artificial, um agente é qualquer entidade capaz de perceber o ambiente por meio de sensores, tomar decisões com base nessas percepções e agir sobre o ambiente por meio de atuadores para alcançar determinados objetivos. Um agente racional é aquele que, para cada situação percebida, escolhe a ação que maximiza seu desempenho esperado, considerando o conhecimento disponível, as limitações do ambiente e os objetivos definidos, buscando sempre a melhor ação possível dentro dessas condições.

Os agentes de inteligência artificial são sistemas de software que usam a inteligência artificial para alcançar objetivos e concluir tarefas em nome dos usuários. Eles demonstram raciocínio, planejamento e memória, com autonomia para tomar decisões, aprender e se adaptar. Esses recursos são possíveis em grande parte pela capacidade multimodal da inteligência artificial generativa e dos modelos de fundação de IA. Os agentes de IA podem processar informações multimodais, como texto, voz, vídeo, áudio, código e muito mais, simultaneamente – eles podem conversar, raciocinar, aprender e tomar decisões.

Em Inteligência Artificial, racionalidade descreve como um agente decide. Um agente racional é aquele que, dadas suas percepções, conhecimentos e limitações, escolhe a ação que maximiza o desempenho esperado em relação a um critério definido. Eles podem aprender com o tempo e facilitar transações, além de poderem trabalhar com outros agentes para coordenar e executar fluxos de trabalho mais complexos. Embora os principais recursos de um agente de IA sejam o raciocínio e a ação, mais recursos evoluíram com o tempo. Vejamos seus principais recursos:

RECURSOS	DESCRIÇÃO
RACIOCÍNIO	Capacidade de usar lógica e informações disponíveis para tirar conclusões, fazer inferências e resolver problemas, analisando dados e padrões para tomar decisões fundamentadas no contexto e em evidências.
AÇÃO	Habilidade de executar tarefas com base em decisões ou planos definidos, interagindo com o ambiente por meio de ações físicas ou digitais, como enviar mensagens, atualizar sistemas ou acionar processos automatizados.
OBSERVAÇÃO	Capacidade de coletar e interpretar informações do ambiente por meio de linguagem, visão, áudio ou sensores, permitindo compreender o contexto atual e fornecer subsídios para decisões mais conscientes.
PLANEJAMENTO	Aptidão para definir estratégias e sequências de ações visando alcançar objetivos, avaliando alternativas, prevendo estados futuros e considerando restrições, riscos e possíveis obstáculos ao longo do processo.
COLABORAÇÃO	Capacidade de cooperar com humanos ou outros agentes de IA, envolvendo comunicação, coordenação e alinhamento de objetivos, permitindo a execução conjunta de tarefas e fluxos de trabalho complexos.
APRIMORAMENTO	Habilidade de aprender com experiências e feedback, ajustando comportamentos e estratégias ao longo do tempo para melhorar desempenho, eficiência e qualidade das decisões tomadas pelo agente.

Estrutura de Agentes

Agora vamos aprofundar um pouco mais nos elementos que estruturam os agentes de IA modernos. Cada agente é projetado com um conjunto de componentes que definem seu papel, sua maneira de interagir e até seu comportamento. Um dos primeiros elementos importantes é a persona. Ter uma persona bem definida permite que o agente mantenha um caráter consistente, ou seja, que ele fale, se comporte e reaja de forma adequada ao papel que está desempenhando – seja como tutor, consultor jurídico ou atendente de suporte técnico. E mais: com o tempo, essa persona pode evoluir, adaptando-se à medida que o agente ganha experiência ou recebe feedback.

Outro componente essencial é a memória. Diferente de um sistema que responde apenas com base na última pergunta, os agentes podem ser equipados com diferentes tipos de memória: curto prazo, para lidar com interações imediatas dentro de uma conversa; longo prazo, para armazenar informações históricas e interações passadas; memória episódica, que foca em eventos específicos ou interações marcantes; e memória de consenso, útil quando múltiplos agentes compartilham conhecimento ou coordenam ações. Isso tudo permite que o agente mantenha o contexto, aprenda com suas interações e melhore seu desempenho ao longo do tempo.

As ferramentas também têm um papel importante. Elas são os recursos externos que o agente pode usar para interagir com o ambiente ou executar ações mais complexas. Isso inclui desde consultas a bancos de dados até comandos em sistemas, chamadas de APIs ou controle de dispositivos. Dependendo da interface, essas ferramentas podem ser físicas (como sensores), gráficas (como dashboards) ou programáticas. E veja bem: não basta o agente ter acesso a uma ferramenta – ele precisa aprender a usá-la corretamente e saber quando aplicá-la.

Não podemos esquecer do componente central de tudo isso: o modelo. Os LLMs são o coração dos agentes de IA, porque é com base neles que o agente entende comandos, interpreta contexto, gera respostas e até realiza raciocínios mais sofisticados. É como se o LLM fosse o cérebro, enquanto os demais componentes (memória, ferramentas, persona) funcionassem como os sentidos, os músculos e a personalidade do agente. É essa combinação que permite aos agentes não apenas conversar, mas agir e colaborar de maneira útil e eficaz em ambientes reais ou virtuais.

Sistemas Conversacionais e Assistentes

Nos últimos anos, a Inteligência Artificial (IA) deixou de ser uma tecnologia distante e passou a fazer parte das ferramentas que utilizamos no dia a dia. Em áreas como análise de dados, planilhas eletrônicas e Business Intelligence, a IA atua como um assistente inteligente, capaz de automatizar tarefas, analisar informações rapidamente e gerar insights que antes só especialistas conseguiam produzir.

Esses assistentes não substituem o usuário – ao contrário, tornam o trabalho mais rápido, preciso e produtivo. Para quem trabalha com planilhas, relatórios, dashboards ou manipulação de dados, dominar essas ferramentas passou a ser uma habilidade essencial. Temos atualmente no mercado centenas de tecnologias de Inteligência Artificial Generativa. Vamos ver as principais:

Agentes x Assistentes x Bots

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

Uma dúvida comum no fórum é: qual é a diferença entre Agentes de IA, Assistentes de IA e Bots? Essa distinção pode parecer sutil, mas faz bastante diferença na prática. Os agentes de IA são sistemas inteligentes baseados em modelos como os LLMs e projetados para tomar decisões, executar ações e interagir com ambientes externos de forma autônoma ou semiautônoma. Eles são capazes de usar ferramentas, planejar e agir com base em objetivos definidos. Em alguns casos, inclusive, eles aprendem com a experiência e reavaliam estratégias conforme o contexto muda.

Já os assistentes de IA são um tipo específico de agente, mas com foco direto no suporte ao usuário humano. Eles são criados para colaborar, responder perguntas, sugerir caminhos e realizar tarefas – mas geralmente com algum grau de supervisão ou comando explícito. Um bom exemplo são os assistentes embutidos em produtos, como o Google Assistente, a Alexa ou o Copilot da Microsoft. Eles ajudam, sugerem, explicam... mas a decisão final e o controle da interação continuam nas mãos do usuário.

Por fim, os bots – como os tradicionais chatbots ou robôs de atendimento – costumam ser bem mais simples. Em geral, eles seguem fluxos predefinidos, com pouca ou nenhuma capacidade de raciocínio real. São úteis para tarefas repetitivas e previsíveis (como informar o saldo de uma conta ou agendar um serviço), mas não conseguem improvisar ou resolver problemas mais complexos como um LLM conseguiria. Claro, hoje em dia muitos bots estão sendo turbinados com LLMs e se tornando mais inteligentes, mas a essência deles ainda é mais restrita.

Agentes Autônomos

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

Os Agentes Autônomos são sistemas de inteligência artificial capazes de perceber o ambiente, tomar decisões e agir de forma independente para alcançar objetivos definidos, sem depender de instruções humanas constantes. Eles recebem entradas por meio de sensores ou dados digitais, processam essas informações e executam ações por meio de atuadores ou interfaces computacionais.

Esses agentes combinam diferentes capacidades, como raciocínio, planejamento, memória e aprendizado, permitindo que adaptem seu comportamento ao longo do tempo. Em vez de responder apenas a comandos pontuais, agentes autônomos podem decompor tarefas complexas em etapas, avaliar alternativas e escolher ações que maximizem seus resultados em contextos dinâmicos.

Na prática, agentes autônomos são aplicados em robótica, jogos, sistemas de recomendação avançados, automação de processos e agentes baseados em LLMs, que interagem com ferramentas externas e outros agentes. Embora potentes, levantam desafios importantes relacionados a controle, alinhamento, segurança e responsabilidade no uso da IA.

Principais Assistentes de IA

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

CRITÉRIO	CHATGPT	MICROSOFT COPILOT	DALL·E	GOOGLE GEMINI	DEEPSEEK
CAPACIDADES E ESCOPO	Conversação, geração de texto, código e multimodal (texto + imagem). Versátil e generalista.	Focado em produtividade: integra Word, Excel, PowerPoint, Outlook, Teams.	Geração de imagens a partir de texto; edição (in/outpainting).	Multimodal (texto, imagem, áudio, vídeo, código, PDFs). Contexto longo (até milhões de tokens).	Modelos abertos, com foco em eficiência, raciocínio lógico e programação.
QUALIDADE DE SAÍDA	Respostas claras, criativas e coerentes; pode alucinar.	Produz conteúdo altamente contextualizado com base nos arquivos do usuário.	Qualidade artística e criativa; bom no estilo ilustrativo, limitações em fotorrealismo/texto em imagem.	Líder em benchmarks de raciocínio e STEM; forte em multimodalidade.	Comparável a GPT-4 em matemática, lógica e benchmarks técnicos; custo baixo.
INTEGRAÇÃO E ECOSISTEMA	API aberta, plugins, apps móveis/web.	Integrado ao Microsoft 365 e Azure.	Integrado ao ChatGPT, Bing e Designer; API OpenAI.	Integrado ao Google Workspace, Chrome, Android, AI Studio e Vertex AI.	API compatível com OpenAI, apps móveis e web; disponível em GitHub/HuggingFace.
INTERFACE E USABILIDADE	Chat simples, apps iOS/Android, web; curva de aprendizado baixa.	Embutido nas ferramentas Office; fácil para usuários já habituados ao ecossistema Microsoft.	Interface intuitiva; basta digitar prompts.	Chat multimodal, suporte a uploads e comandos em vários formatos.	Interface web/app gratuita, API com baixo custo, sem limites de consultas.
PERFORMANCE TÉCNICA	Janela de contexto até 128k tokens; multimodal.	Rápido, baseado em GPT-4, otimizado para produtividade.	Gera imagens em segundos; qualidade variável conforme prompt.	Janela de contexto até 1-2M tokens; raciocínio avançado; suporte a agentes.	Muito eficiente (10x mais barato que GPT-4); contexto até 128k tokens; modelos MoE.
SEGURANÇA E PRIVACIDADE	Conformidade com LGPD/GDPR;	Dados ficam no tenant da empresa; forte	Filtros de segurança contra usos sensíveis;	Compliance empresarial (DLP, HIPAA,	Críticas por censura política;

	Enterprise não usa dados para treino.	compliance corporativa.	bloqueia rostos públicos.	ISO); usuários comuns com retenção de dados até 18 meses.	preocupações sobre privacidade fora da China.
MODELO DE NEGÓCIO	Gratuito (GPT-3.5) e pago (GPT-4/5 Plus, Team, Enterprise).	Assinatura extra no Microsoft 365; sem versão gratuita.	Gratuito limitado (Bing), API paga, créditos adicionais.	Gratuito (básico) e pago (Pro, Ultra); API via Vertex AI.	Gratuito (chat), API paga muito barata; modelos open-source sob MIT.
INOVAÇÃO E EVOLUÇÃO	Evolução rápida (3.5 → 4 → 5); foco em multimodalidade e agentes.	Estratégia de levar IA à produtividade corporativa; novos recursos Office contínuos.	Pioneiro em geração de imagens; DALL-E 3 mais fiel aos prompts e integrado ao ChatGPT.	Avança em raciocínio multimodal, agentes (Astra) e contexto longo; roadmap acelerado.	"Momento Sputnik da IA": evolução rápida, custo baixo e modelos abertos desafiam big techs.

A integração da Inteligência Artificial em ferramentas de planilhas eletrônicas – como Microsoft Excel (via Copilot), Google Sheets (com a função Explorar), LibreOffice Calc (com extensões de terceiros) e Power BI – tem redefinido a forma como usuários interagem com dados. Esses assistentes deixaram de ser meros facilitadores e passaram a atuar como agentes analíticos capazes de compreender o conteúdo das planilhas e oferecer suporte contextualizado.

Entre suas principais funcionalidades, destacam-se: sugestões automáticas de fórmulas e gráficos, correção de inconsistências, automatização de cálculos, resposta a perguntas em linguagem natural, detecção de padrões e identificação de anomalias. A interação com essas ferramentas tornou-se significativamente mais acessível, especialmente para usuários com pouca familiaridade técnica.


O preenchimento inteligente, por exemplo, permite que a IA aplique transformações em colunas inteiras a partir de poucos exemplos fornecidos pelo usuário, otimizando tarefas repetitivas como ajustes de nomes, datas ou formatos. Já na visualização de dados, os assistentes sugerem, de forma automática, os tipos de gráfico mais adequados com base no conjunto de dados selecionado, evitando o processo de tentativa e erro na escolha da melhor representação gráfica.

Recursos como o botão "Ideias" (anteriormente "Insights") no Excel exemplificam a capacidade da IA de analisar conjuntos de dados em busca de tendências, variações significativas e valores atípicos, oferecendo observações que podem subsidiar decisões estratégicas de forma rápida e eficaz. A evolução dos assistentes generativos também permite interações diretas em linguagem natural.

O usuário pode formular perguntas como "qual foi a média de vendas por categoria?" ou "quais produtos aumentaram mais de 15%?", e receber respostas completas, com explicações, fórmulas, gráficos e tabelas automaticamente organizados. Adicionalmente, algumas dessas ferramentas já realizam análises preditivas básicas, como projeções de vendas e estimativas de custos, diretamente nas planilhas, ampliando as possibilidades de tomada de decisão com base em dados históricos.

Contudo, a utilização dessas tecnologias exige cautela. Os modelos de IA podem interpretar dados de forma inadequada, errar cálculos ou desconsiderar contextos organizacionais específicos. A eficácia das respostas continua dependente da qualidade dos dados fornecidos e da supervisão crítica por parte do usuário. Assim, mesmo diante de avanços significativos, o uso responsável da IA pressupõe análise criteriosa e bom senso na interpretação dos resultados.

COMPARATIVO DE MODELOS DE INTELIGÊNCIA ARTIFICIAL: UMA VISÃO GERAL DIDÁTICA



Engenharia de Prompt

INCIDÊNCIA EM PROVA: BAIXA

Conceitos Básicos

ENGENHARIA DE PROMPT

Prática de criar instruções ou comandos otimizados para orientar o comportamento de modelos de inteligência artificial generativa, como o ChatGPT. Ela envolve formular perguntas, contextos e exemplos de forma estratégica para obter respostas mais precisas, úteis e relevantes. Essa técnica é essencial para explorar todo o potencial de modelos de linguagem, seja para gerar textos, programar, responder perguntas ou realizar análises. A engenharia de prompt tornou-se uma habilidade importante para profissionais que usam IA no dia a dia, pois pequenos ajustes na formulação do comando podem alterar significativamente a qualidade do resultado.

A Engenharia de Prompts consiste na formulação precisa de comandos ou instruções em linguagem natural para orientar o comportamento de modelos de Inteligência Artificial generativa. Trata-se de uma prática fundamental para maximizar a eficácia das interações com sistemas como o ChatGPT, DALL-E, entre outros, garantindo que as respostas geradas sejam alinhadas aos objetivos do usuário.

Assim como instruções vagas produzem resultados ambíguos, comandos bem elaborados – com contexto, detalhes e objetivos claros – orientam a IA de forma mais eficaz. Quanto maior a especificidade do prompt, menor a margem de interpretação incorreta por parte do modelo, resultando em saídas mais relevantes, coerentes e adequadas à tarefa proposta.

A analogia com a direção de cena ilustra esse princípio: enquanto um comando genérico (“faça algo interessante”) permite interpretações variadas, uma instrução detalhada (“diga essas palavras com expressão de surpresa e medo”) guia o sistema com precisão. Essa lógica se aplica à IA, que responde melhor quando instruída com clareza sobre o que deve fazer, em qual formato, com qual linguagem e em qual contexto.

Na prática, engenheiros de prompt são profissionais especializados na construção, ajuste e refinamento de instruções para modelos generativos. Atuam em diversas áreas – como criação de conteúdo, atendimento automatizado, análise de dados, automação de processos e design de produtos – otimizando os resultados gerados pela IA conforme as necessidades específicas dos usuários e dos sistemas.

A Engenharia de Prompts não é um algoritmo, interface ou sistema computacional. É uma técnica de formulação textual, baseada em linguagem natural (ou estruturada), cujo objetivo é orientar modelos de IA na execução de tarefas como redação, geração de imagens, produção de código, síntese de dados ou qualquer outra aplicação generativa. Logo, trata-se de uma competência essencial na interação com modelos de linguagem avançados, sendo cada vez mais valorizada como interface crítica entre o usuário humano e os sistemas automatizados de geração de conteúdo.

Principais Técnicas

Existem diversas técnicas de engenharia de prompt, que são basicamente estratégias estruturadas para formular instruções (prompts) de forma a orientar modelos de linguagem a produzir respostas mais precisas, controladas, coerentes e alinhadas ao objetivo da tarefa. Em termos simples, não se trata apenas de o que perguntar, mas de como perguntar. Vejamos as principais técnicas:

TÉCNICAS	DESCRIÇÃO	EXEMPLO DE PROMPT
ZERO SHOT	Técnica em que o modelo recebe apenas a instrução da tarefa, sem exemplos prévios ou dicas adicionais. Depende exclusivamente do conhecimento pré-treinado para interpretar o pedido e produzir a resposta esperada.	Explique o conceito de Big Data, descrevendo suas principais características, sem usar exemplos longos, mantendo linguagem clara e objetiva, adequada a um leitor iniciante no tema.
CHAIN OF THOUGHT (COT)	Técnica que incentiva o modelo a externalizar seu raciocínio lógico em etapas sequenciais antes de apresentar a resposta final, aumentando a precisão em tarefas que exigem inferência, lógica ou cálculo.	Resolva o problema apresentado explicando detalhadamente cada passo do raciocínio utilizado, mostrando como cada conclusão parcial leva à próxima, antes de apresentar a resposta final.
FEW SHOT PROMPTING	Técnica que fornece poucos exemplos resolvidos no próprio prompt para orientar o modelo sobre o padrão esperado de resposta, formato, estilo ou tipo de raciocínio desejado pelo usuário.	Pergunta: $2+2=4$. Pergunta: $3+3=6$. Pergunta: $4+4=8$. Agora, seguindo exatamente o mesmo padrão de raciocínio e resposta, resolva a seguinte pergunta: $7+7=?$
ZERO SHOT COT	Variação do Chain of Thought em que não são fornecidos exemplos, mas o prompt solicita explicitamente que o modelo raciocine passo a passo, guiando-o a estruturar internamente a solução.	Resolva a questão apresentada explicando o raciocínio passo a passo, deixando claro como cada etapa contribui para a solução final, mesmo sem exemplos prévios no enunciado.
SELF-CONSISTENCY	Técnica que gera múltiplas cadeias de raciocínio independentes para o mesmo problema e seleciona a resposta mais recorrente, reduzindo erros ocasionais e aumentando a robustez da decisão final.	Resolva o mesmo problema cinco vezes, utilizando raciocínios independentes. Ao final, compare os resultados obtidos e informe como resposta final aquela que aparecer com maior frequência.
TREE OF THOUGHTS	Técnica que estimula o modelo a explorar diferentes caminhos de raciocínio em paralelo, avaliando alternativas	Analise o problema explorando pelo menos três abordagens diferentes. Avalie os prós e contras de cada

	intermediárias antes de escolher a solução mais promissora, semelhante a uma árvore de decisões.	caminho de raciocínio e, ao final, selecione a solução mais consistente.
ROLE PROMPTING	Técnica em que o modelo assume explicitamente um papel profissional ou social específico, o que ajuda a ajustar vocabulário, nível de detalhe, tom da resposta e critérios de avaliação do conteúdo produzido.	Você é um professor universitário de banco de dados. Explique o conceito solicitado utilizando linguagem didática, exemplos simples e foco pedagógico, como se estivesse ensinando alunos iniciantes.
INSTRUCTION PROMPTING	Técnica baseada em instruções claras, detalhadas e explícitas sobre formato, estilo, limites e objetivos da resposta, reduzindo ambiguidades e aumentando a previsibilidade do resultado gerado.	Explique o tema solicitado em no máximo 200 palavras, utilizando linguagem técnica, sem analogias, estruturando a resposta em dois parágrafos e incluindo pelo menos um exemplo conceitual.
REACT (REASON + ACT)	Técnica que combina raciocínio explícito com ações práticas, como consultas a ferramentas ou bases externas, permitindo que o modelo pense, aja, observe resultados e refine a resposta iterativamente.	Analise a pergunta, descreva seu raciocínio inicial, consulte os dados disponíveis quando necessário, interprete os resultados obtidos e, somente então, apresente a resposta final fundamentada.
DECOMPOSITION PROMPTING	Técnica que divide um problema complexo em subtarefas menores e mais simples, permitindo que o modelo trate cada parte separadamente antes de integrar tudo em uma resposta final coerente.	Primeiro identifique os conceitos centrais do problema. Em seguida, explique cada conceito individualmente. Por fim, relacione todos eles para construir a resposta completa solicitada.
STEP-BY-STEP PROMPTING	Técnica que força o modelo a seguir uma sequência linear de resolução, abordando cada etapa de forma explícita e ordenada, mesmo em tarefas que não exigem exemplos prévios.	Resolva a questão seguindo etapas claras e numeradas. Não apresente a resposta final antes de concluir todas as etapas intermediárias do raciocínio solicitado no enunciado.
SELF-CRITIQUE / REFLEXION	Técnica em que o modelo revisa sua própria resposta, identifica possíveis erros, inconsistências ou lacunas conceituais e, em seguida, produz uma versão corrigida e aprimorada.	Apresente sua resposta inicial. Em seguida, revise criticamente o que foi escrito, identifique eventuais falhas conceituais ou imprecisões e forneça uma versão final corrigida.
LEAST-TO-MOST PROMPTING	Técnica que orienta o modelo a resolver inicialmente versões mais simples do problema, usando essas soluções como base para lidar progressivamente com versões mais complexas da tarefa.	Comece resolvendo um exemplo simples do problema. Depois, utilize o raciocínio obtido para resolver um caso intermediário e, por fim, generalize para a situação completa apresentada.
RETRIEVAL-AUGMENTED PROMPTING (RAG)	Técnica que combina o modelo com informações externas recuperadas de documentos ou bases de dados, reduzindo alucinações e garantindo que a resposta seja fundamentada em fontes fornecidas.	Com base exclusivamente no texto fornecido a seguir, responda à pergunta proposta. Não utilize conhecimento externo nem faça suposições além das informações presentes no material.
CONSTRAINT-BASED PROMPTING	Técnica que impõe restrições rígidas ao conteúdo ou à forma da resposta, como proibição de opiniões, exemplos ou	Defina o conceito solicitado utilizando apenas linguagem formal, sem exemplos práticos, sem analogias e sem

	analogias, garantindo aderência estrita a normas ou critérios definidos.	emitir opiniões pessoais, limitando-se a definições técnicas objetivas.
MULTI-PERSONA PROMPTING	Técnica que solicita múltiplas respostas a partir de diferentes pontos de vista ou papéis, permitindo comparar perspectivas distintas e enriquecer análises críticas ou decisões complexas.	Responda à pergunta primeiro como um engenheiro de dados, focando aspectos técnicos. Em seguida, responda como um gestor, priorizando impacto organizacional e tomada de decisão.

QUESTÕES COMENTADAS

1. (FGV / CNU - 2025) Em relação aos desafios presentes na relação entre Inteligência Artificial Generativa (IAG) e comunicação ética, analise as afirmativas a seguir.

I. O uso de dados gerados por inteligência artificial deve cumprir as regulamentações vigentes, embora enfrente desafios impostos pelo rápido avanço tecnológico, que frequentemente supera a velocidade da elaboração legislativa.

II. O uso de dados gerados por inteligência artificial deve respeitar a privacidade e a proteção de dados, embora enfrente desafios para assegurar a defesa contra usos indevidos.

III. O uso de dados gerados por inteligência artificial deve se pautar na autonomia exercida pela própria IA em relação à supervisão humana, embora enfrente desafios para promover uma comunicação clara e eficiente.

Está correto o que se afirma em:

- a) I, apenas;
- b) I e II, apenas
- c) I e III, apenas;
- d) II e III, apenas;
- e) I, II e III.

Comentários:

(I) Correto. O uso de dados gerados por IA deve seguir regulamentações, enfrentando o desafio da velocidade do avanço tecnológico em relação à legislação, que muitas vezes não acompanha essa evolução.

(II) Correto. A proteção da privacidade é essencial no uso de dados de IA, e os desafios para evitar usos indevidos são significativos, exigindo medidas rigorosas de segurança.

(III) Errado. A autonomia da IA não deve ser priorizada em detrimento da supervisão humana, pois isso pode comprometer a clareza e a eficiência na comunicação, que dependem da intervenção humana.

Gabarito: Letra B

2. (FGV / CNU - 2025) No setor público, as ferramentas de Inteligência Artificial Generativa (IAG) oferecem oportunidades para modernizar processos, como automação de tarefas repetitivas, redação de documentos e criação de materiais visuais. Contudo, sua implementação precisa de supervisão humana para que vieses ou informações imprecisas não sejam reproduzidos, especialmente em instituições públicas que lidam com informações sensíveis e de impacto

social. A fase do ciclo de desenvolvimento de modelos de IAG na qual ocorre essa supervisão, com o ajuste e a captura de padrões nos dados, é a de:

- a) aplicação;
- b) inferência;
- c) alucinação;
- d) implantação;
- e) treinamento.

Comentários:

- (a) Errado. A fase de aplicação refere-se ao uso do modelo já treinado, não à supervisão e ajuste dos dados.
- (b) Errado. A inferência é a fase em que o modelo faz previsões com base em dados novos, sem ajustes ou supervisão.
- (c) Errado. Alucinação é um termo que descreve quando o modelo gera informações incorretas, não é uma fase do desenvolvimento.
- (d) Errado. A implantação é a fase em que o modelo é colocado em operação, não envolve supervisão ou ajuste de padrões.
- (e) Correto. O treinamento é a fase em que ocorre a supervisão e ajuste dos dados, capturando padrões para melhorar a performance do modelo.

Gabarito: Letra E

3. (FGV / TCE-PE - 2025) Muitos cenários de análise de dados envolvem conjuntos sem rótulos disponíveis, como é comum em agrupamentos de clientes, detecção de padrões anômalos ou redução de dimensionalidade. Nesses casos, técnicas de aprendizado não supervisionado são essenciais para extrair conhecimento oculto nos dados.

Com relação ao aprendizado não supervisionado em Machine Learning, assinale a afirmativa correta.

- a) O aprendizado não supervisionado depende de conjuntos de dados previamente rotulados para mapear entradas a saídas durante o treinamento.
- b) Técnicas de aprendizado não supervisionado, como árvores de decisão e regressão logística, são ideais para prever rótulos em problemas de classificação supervisionada.
- c) O aprendizado não supervisionado é utilizado para gerar automaticamente rótulos com base em padrões nos dados, sem necessidade de saídas conhecidas previamente.

- d) A principal limitação do aprendizado não supervisionado é que ele não consegue lidar com grandes volumes de dados, sendo restrito a pequenos conjuntos.
- e) O aprendizado não supervisionado só pode ser utilizado quando todos os atributos do conjunto de dados forem categóricos.

Comentários:

- (a) Errado. Aprendizado não supervisionado não depende de rótulos; ele busca estrutura/padrões nos dados sem saídas conhecidas no treino.
- (b) Errado. Árvores de decisão e regressão logística são técnicas típicas de aprendizado supervisionado, voltadas a prever rótulos já definidos.
- (c) Correto. Identifica padrões/estruturas (ex.: clusters, anomalias) e pode inferir agrupamentos que servem como "rótulos" gerados a partir dos dados.
- (d) Errado. Não há essa restrição "a pequenos conjuntos"; a limitação central é a ausência de rótulos para validação direta, não o volume em si.
- (e) Errado. Pode trabalhar com atributos numéricos e categóricos; não exige que todos os atributos sejam categóricos.

Gabarito: Letra C

4. (FGV / TCE-PE - 2025) No campo da inteligência artificial, os agentes desempenham papel central como entidades capazes de perceber o ambiente, tomar decisões e agir com base em metas definidas. Compreender sua estrutura e tipos é fundamental para o desenvolvimento de sistemas inteligentes. Assinale a afirmativa que descreve corretamente uma característica de agentes de inteligência artificial.

- a) Um agente reativo simples armazena historicamente os estados anteriores do ambiente para prever ações futuras com base em aprendizado profundo.
- b) Agentes baseados em objetivos não consideram o estado atual do ambiente, mas tomam decisões aleatórias até alcançarem a meta desejada.
- c) Agentes baseados em utilidade avaliam diferentes cursos de ação e escolhem aquele que maximiza um valor numérico associado à satisfação da meta.
- d) Um agente só pode ser considerado inteligente se tiver consciência própria e habilidades linguísticas semelhantes às humanas.
- e) Agentes de IA operam exclusivamente em ambientes totalmente observáveis e determinísticos, pois exigem informações completas para funcionar.

Comentários:

- (a) Errado. Agente reativo simples não mantém histórico nem usa aprendizado profundo; reage ao estado/percepção atual por regras condição-ação.
- (b) Errado. Agentes baseados em objetivos consideram o estado atual e planejam ações para atingir a meta, não decidem aleatoriamente.
- (c) Correto. Agentes baseados em utilidade comparam alternativas e escolhem a ação que maximiza uma função numérica de utilidade (grau de satisfação da meta).
- (d) Errado. Inteligência em agentes não exige autoconsciência nem linguagem humana; basta perceber, decidir e agir de forma racional conforme metas.
- (e) Errado. Agentes podem atuar em ambientes parcialmente observáveis e/ou estocásticos, usando crenças/estimativas; não dependem de informação completa.

Gabarito: Letra C

5. (FGV / CNU - 2025) Martin está elaborando uma cartilha sobre o uso ético da Inteligência Artificial (IA) em seu setor, que atua no atendimento ao público. Para isso, a IA deve fornecer informações sobre as entradas, as saídas e o funcionamento do algoritmo utilizado, bem como a forma como cada parte contribui para o resultado final. Na cartilha de uso ético da IA de Martin, devem constar requisitos sobre:

- a) explicabilidade;
- b) hiperparametrização;
- c) aprendizado profundo;
- d) modelos largos de linguagem;
- e) processamento de linguagem natural.

Comentários:

- (a) Correto. Explicabilidade exige transparência sobre entradas, saídas e lógica do algoritmo, indicando como cada componente influencia o resultado, o que é central no uso ético da IA no atendimento ao público.
- (b) Errado. Hiperparametrização trata de ajustes de treinamento (parâmetros do modelo), não de explicar decisões, entradas/saídas e contribuições para o resultado final.
- (c) Errado. Aprendizado profundo é uma abordagem/modelagem (redes neurais), mas não é, por si, um requisito ético de transparência e prestação de contas do sistema.

(d) Errado. Modelos largos de linguagem descrevem um tipo de modelo (LLM), enquanto o enunciado pede requisito de compreensão/justificativa do funcionamento e do resultado.

(e) Errado. Processamento de linguagem natural é uma área/técnica para lidar com texto e fala, não um requisito voltado a tornar o algoritmo compreensível e auditável.

Gabarito: Letra A

6. (FGV / TCE-PE - 2025) Com relação aos Grandes Modelos de Linguagens (LLMs), avalie as afirmativas a seguir e assinale (V) para verdadeira e (F) para falsa.

() LLMs são capazes de fazer inferências a partir de um contexto, gerar respostas contextualmente relevantes, traduzir documentos para outros idiomas, resumir textos, responder a perguntas ou mesmo auxiliar em tarefas de redação criativa ou geração de código.

() Os LLMs representam um avanço considerável no processamento de linguagem natural (PNL) e tornaram-se facilmente acessíveis ao público por meio de interfaces como o Chat GPT-3 e o GPT-4. Outros exemplos de LLMs são os modelos Llama e as representações de codificadores bidirecionais, como BERT e RoBERTa.

() LLM é um modelo de aprendizado de máquina que pode ser usado na inteligência artificial generativa, capaz de executar diferentes funções. Os LLM são treinados a partir de grandes volumes de dados.

As afirmativas são, segundo a ordem apresentada,

- a) V - F - V.
- b) V - F - F.
- c) V - V - V.
- d) F - V - V.
- e) F - V - F.

Comentários:

(I) Correto. LLMs realmente têm a capacidade de fazer inferências, gerar respostas relevantes e auxiliar em diversas tarefas, como tradução e redação criativa.

(II) Correto. Os LLMs, como GPT-3 e GPT-4, representam um avanço significativo em PNL e são amplamente acessíveis, incluindo modelos como Llama, BERT e RoBERTa.

(III) Correto. LLMs são modelos de aprendizado de máquina usados em IA generativa, treinados com grandes volumes de dados para executar diversas funções.

Gabarito: Letra C

7. (FGV / TCE-PE - 2025) Com o avanço do deep learning, redes neurais profundas e grandes modelos de linguagem (LLMs) vêm sendo amplamente utilizados em aplicações como tradução automática, geração de texto, reconhecimento de imagens e assistentes virtuais. A respeito de redes neurais profundas, deep learning e grandes modelos de linguagem (LLMs), assinale a afirmativa correta.

- a) Redes neurais profundas possuem apenas uma camada oculta entre a entrada e a saída e são ideais para tarefas simples de classificação linear.
- b) O termo deep learning refere-se a técnicas que dispensam o uso de redes neurais artificiais, utilizando apenas algoritmos estatísticos tradicionais.
- c) Os grandes modelos de linguagem (LLMs) são caracterizados por seu tamanho reduzido, pois dependem de poucos parâmetros para evitar sobrecarga computacional.
- d) Os grandes modelos de linguagem (LLMs) utilizam arquiteturas de redes neurais profundas, como os transformadores, para processar sequências de texto e aprender padrões complexos.
- e) Redes neurais profundas são indicadas exclusivamente para reconhecimento de imagens e não são aplicadas em processamento de linguagem natural.

Comentários:

- (a) Errado. Redes profundas têm várias camadas ocultas (não apenas uma) e não se limitam a classificação linear, sendo usadas para padrões complexos.
- (b) Errado. Deep learning está diretamente ligado ao uso de redes neurais (especialmente profundas), e não à dispensa delas em favor de estatística "tradicional".
- (c) Errado. LLMs se destacam justamente pelo grande número de parâmetros e alta capacidade, o que aumenta (não reduz) a demanda computacional.
- (d) Correto. LLMs empregam arquiteturas profundas, como Transformers, para modelar sequências de texto e capturar dependências e padrões complexos.
- (e) Errado. Redes profundas também são amplamente aplicadas em PLN (NLP), como tradução, geração de texto e chatbots, não ficando restritas a imagens.

Gabarito: Letra D

8. (FGV / TCE-PE - 2025) Com a popularização de modelos de linguagem de grande escala (LLMs), como o GPT e o Claude, a engenharia de prompt tornou-se uma habilidade essencial para direcionar corretamente esses modelos, extraindo respostas mais úteis, seguras e alinhadas ao

objetivo do usuário. Em relação às boas práticas de engenharia de prompt aplicadas a grandes modelos de linguagem (LLMs), assinale a afirmativa correta.

- a) A engenharia de prompt exige conhecimento profundo de linguagens de programação, pois os prompts devem ser escritos em linguagens formais como Python ou SQL.
- b) Prompts vagos e abertos tendem a melhorar a criatividade dos modelos e garantem maior precisão, especialmente em tarefas críticas e factuais.
- c) Instruções explícitas, exemplos no prompt e delimitação clara da tarefa aumentam a probabilidade de o LLM produzir respostas relevantes e adequadas ao objetivo.
- d) LLMs interpretam todos os prompts da mesma forma, independentemente da estrutura, do idioma ou da ordem em que as informações são fornecidas.
- e) A engenharia de prompt não tem impacto sobre a segurança das respostas geradas, já que os LLMs seguem regras internas fixas de filtragem de conteúdo.

Comentários:

- (a) Errado. Prompt é texto em linguagem natural; não exige escrever em Python/SQL, embora possa incluir trechos técnicos quando útil.
- (b) Errado. Vagueza pode aumentar variação/criatividade, mas não “garante” precisão; em tarefas factuais e críticas, especificidade reduz ambiguidades.
- (c) Correto. Instruções claras, exemplos (few-shot) e delimitação do escopo orientam o modelo, elevando a chance de respostas relevantes e alinhadas ao objetivo.
- (d) Errado. Estrutura, idioma, contexto e ordem influenciam a interpretação e a qualidade da saída; prompts bem organizados tendem a performar melhor.
- (e) Errado. O prompt impacta segurança (ex.: restrições, contexto e limites); boas práticas ajudam a reduzir riscos e a orientar respostas mais seguras.

Gabarito: Letra C

9. (FGV / TCE-PE - 2025) Os grandes modelos de linguagem, também conhecidos como LLMs (Large Language Model),

- a) empregam uma tabela numérica para representar cada palavra, o que possibilita reconhecer relações entre palavras, como vocábulos com significados semelhantes.
- b) correspondem a um conjunto de redes neurais em que cada uma consiste em um codificador e um decodificador com recursos de recorrência e convoluções.

- c) processam entradas sequencialmente, o que potencializa a realização dos cálculos mais complexos.
- d) utilizam vetores multidimensionais, conhecidos como incorporações de palavras, para representá-las de modo que aquelas com significados contextuais semelhantes ou com outras relações fiquem próximas entre si no espaço vetorial.
- e) processam sequências inteiras em paralelo, empregando recursos de recorrência e convoluções, o que possibilita o uso extensivo de GPUs (Graphics Processing Units) para treinar LLMs.

Comentários:

- (a) Errado. LLMs não usam “tabela numérica por palavra” de forma fixa; a representação moderna é vetorial e depende do contexto, não apenas de um índice/tabela.
- (b) Errado. A descrição remete a arquiteturas com codificador/decodificador e recorrência/convolução, o que não caracteriza os LLMs atuais de forma geral.
- (c) Errado. A ideia de processamento estritamente sequencial não é a característica central; o foco é modelar linguagem com representações que permitam eficiência no treinamento.
- (d) Correto. Usam vetores multidimensionais (embeddings) para representar palavras/tokens, aproximando no espaço vetorial termos com relações e significados contextuais semelhantes.
- (e) Errado. Mistura paralelismo com “recorrência e convoluções”; o uso extensivo de GPUs decorre do paralelismo, mas LLMs não se definem por recorrência/convolução.

Gabarito: Letra D

10.(FGV / MACAEPREV - 2024) Large Language Models (LLMs) são um tipo de modelo IA projetado para lidar com tarefas de processamento de linguagem natural (PLN) em uma escala muito grande. Esses modelos são treinados com enormes quantidades de dados textuais e são capazes de entender e gerar texto em linguagem natural de forma altamente sofisticada. Em relação aos Large Language Models (LLMs), como o GPT, a abordagem mais relevante para melhorar a capacidade do modelo de gerar respostas coerentes e contextualmente apropriadas em conversas prolongadas, entre as listadas, é

- a) aumentar o número de parâmetros do modelo.
- b) utilizar a técnica de fine-tuning em um grande conjunto de dados não rotulados.
- c) implementar um mecanismo de atenção (Attention Mechanism).
- d) aplicar a tokenização BPE (Byte Pair Encoding) ao texto de entrada.
- e) aumentar a frequência de palavras raras no conjunto de treinamento.

Comentários:

- (a) Errado. Mais parâmetros podem melhorar desempenho geral, mas não garantem, por si só, coerência e manutenção de contexto em diálogos longos.
- (b) Errado. Fine-tuning em dados não rotulados tende a não alinhar o modelo para conversação; o ganho de coerência contextual não é o foco principal dessa abordagem.
- (c) Correto. O mecanismo de atenção permite ao modelo “focar” em partes relevantes do histórico, capturando dependências de longo alcance e mantendo respostas coerentes e contextuais.
- (d) Errado. BPE melhora a representação de palavras/subpalavras e cobertura de vocabulário, mas não é o fator central para sustentar contexto em conversas prolongadas.
- (e) Errado. Reponderar palavras raras altera a distribuição do treino, mas não resolve o problema de acompanhar e relacionar informações ao longo do diálogo.

Gabarito: Letra C

11.(FGV / TCE-PA - 2024) O campo da inteligência artificial generativa é dedicado ao desenvolvimento de algoritmos capazes de gerar novas instâncias de dados. Suas aplicações incluem, por exemplo, a criação de textos, imagens, áudio e vídeo. As redes generativas adversárias (Generative Adversarial Networks - GANs) são um exemplo de IA generativa que possuem arquitetura baseada em duas redes, chamadas geradora e discriminadora, que competem entre si. Um dos principais problemas das GANs ocorre quando a rede geradora produz apenas uma quantidade limitada de tipos de dados, mesmo que seus dados de treinamento sejam mais ricos e diversificados. Isso ocorre porque a rede geradora consegue “enganar” a rede discriminadora mais facilmente quando dados daqueles tipos específicos são produzidos. A esse fenômeno dá-se o nome de

- a) Falha de Convergência (Convergence Failure).
- b) Sobreajuste (Overfitting).
- c) Colapso de Modo (Mode Collapse).
- d) Filtragem Estocástica (Stochastic Filtering).
- e) Crescimento de Padrões Frequentes (Frequent Pattern Growth).

Comentários:

- (a) Errado. Falha de Convergência refere-se à incapacidade do modelo de encontrar um ponto de equilíbrio durante o treinamento, não ao problema de gerar dados limitados.
- (b) Errado. Sobreajuste ocorre quando o modelo se adapta excessivamente aos dados de treinamento, mas não é o fenômeno que limita a diversidade dos dados gerados.
- (c) Correto. O Colapso de Modo é o fenômeno em que a rede geradora produz um número restrito de tipos de dados, enganando facilmente a rede discriminadora.

(d) Errado. Filtragem Estocástica não é um termo utilizado para descrever o problema de limitação na diversidade de dados gerados por GANs.

(e) Errado. Crescimento de Padrões Frequentes é um conceito relacionado a mineração de dados e não se aplica ao contexto das GANs.

Gabarito: Letra C

12.(FGV / TCE-PA - 2024) O uso de Inteligência Artificial generativa é de grande utilidade para desenvolvedores web, por permitir a criação rápida de ilustrações e gráficos de alta qualidade. Por exemplo, uma das ferramentas mais populares atualmente é a aplicação Crayion, anteriormente conhecida como DALL-E mini, por ser uma ferramenta de acesso livre com interface amigável. No entanto, essas ferramentas podem frustrar os usuários por apresentarem limitações que inviabilizam o uso dos elementos visuais criados a partir de seus resultados. A respeito das tendências no uso de IA generativa em design web, avalie as afirmativas a seguir:

I. Há limitações éticas relacionadas à reprodução de potenciais vieses discriminatórios, provenientes das bases de dados de treinamento das redes generativas.

II. Sua principal vantagem consiste na eliminação de elementos de propriedade intelectual protegida nas imagens geradas, garantindo aos desenvolvedores a não-obrigatoriedade de pagamentos de direitos autorais.

III. Há preocupações com relação à geração de imagens extremamente realistas e com o potencial uso dos chamados "deepfakes" em campanhas de desinformação.

Está correto o que se afirma em

- a) I, apenas.
- b) I e II, apenas.
- c) I, II e III.
- d) II e III, apenas.
- e) I e III, apenas.

Comentários:

(I) Correto. A IA generativa pode reproduzir vieses discriminatórios, pois é treinada em dados que podem conter preconceitos, refletindo-os nas imagens geradas. Isso levanta questões éticas significativas.

(II) Errado. A eliminação de elementos de propriedade intelectual não é garantida, pois as imagens geradas podem ainda infringir direitos autorais, dependendo de como foram criadas e dos dados utilizados.

(III) Correto. A geração de imagens realistas levanta preocupações sobre deepfakes, que podem ser usados para desinformação, afetando a confiança nas mídias visuais.

Gabarito: Letra E

13.(FGV / Prefeitura de Caraguatatuba - SP - 2024) Considere as seguintes afirmativas sobre Inteligência Artificial, assinale V para a afirmativa verdadeira e F para a falsa.

- () A Inteligência Artificial é uma tecnologia disruptiva que tem o potencial de mudar o mundo.**
- () A Inteligência Artificial é utilizada em diversas aplicações práticas, como carros autônomos, assistentes virtuais e sistemas de recomendação.**
- () A Inteligência Artificial não apresenta riscos éticos, pois é uma ferramenta que pode ser usada para o bem ou para o mal, dependendo das intenções de seus usuários.**

As afirmativas são, respectivamente,

- a) V - F - F.
- b) V - V - V.
- c) F - V - V.
- d) V - F - V.
- e) V - V - F.

Comentários:

(V) A Inteligência Artificial é considerada uma tecnologia disruptiva, pois transforma profundamente setores como saúde, transporte, educação e comunicação;

(V) A IA já é usada em carros autônomos, assistentes virtuais (como Alexa e Siri) e sistemas de recomendação (como Netflix e Amazon);

(F) A IA apresenta, sim, riscos éticos, que vão além das intenções dos usuários. Esses riscos envolvem viés algorítmico, privacidade, discriminação, entre outros – o que exige supervisão e regulamentação adequadas.

Gabarito: Letra E

14.(FGV / EPE - 2024) Há uma família de modelos de IA generativa que tem dois modelos treinados em conjunto: o gerador e o discriminador. O gerador tenta criar dados falsos que sejam indistinguíveis dos dados reais, enquanto que o discriminador tenta distinguir entre dados reais e falsos. O treinamento é um jogo min-max, em que o gerador melhora suas habilidades para enganar o discriminador, e o discriminador melhora suas habilidades para detectar dados falsos. Assinale a opção que apresenta as características do modelo de IA generativa descritas no texto.

- a) Generative Adversarial Networks.
- b) Variational Autoencoders.

- c) Energy-Based Models.
- d) Autoregressive Models.
- e) Normalizing Flow Models.

Comentários:

(a) Correto. O modelo descrito no enunciado é uma Rede Generativa Adversária (Generative Adversarial Network - GAN), composta por dois modelos: o gerador, que tenta criar dados realistas, e o discriminador, que tenta distinguir entre dados reais e gerados. Eles são treinados em um processo adversarial (jogo min-max), onde ambos evoluem para melhorar seu desempenho;

(b) Errado. Variational Autoencoders (VAEs) também são usados para geração de dados, mas seu funcionamento não envolve um gerador e um discriminador adversários, e sim a compressão e reconstrução de dados;

(c) Errado. Energy-Based Models definem uma função de energia para aprender representações, mas não seguem a dinâmica adversarial de GANs;

(d) Errado. Autoregressive Models geram dados sequência por sequência (como no GPT), mas não envolvem um discriminador como nas GANs;

(e) Errado. Normalizing Flow Models transformam distribuições simples em complexas de forma reversível, mas também não envolvem a estrutura adversarial entre dois modelos.

Gabarito: Letra A

15.(FGV / CGM de Belo Horizonte - MG - 2024) Relacione os termos de Inteligência Artificial (IA) às suas respectivas definições.

1. IA fraca
2. IA forte
3. IA generativa
4. Teste de Turing

() É capaz de resolver uma única tarefa, pode automatizar tarefas demoradas e analisar dados de maneiras que os humanos às vezes não podem.

() É uma categoria de algoritmos de IA que gera novos resultados com base nos dados em que foram treinados.

() É capaz de resolver uma gama extensa e arbitrária de tarefas, incluindo aquelas que são novas, e executá-las com eficácia comparável à de um ser humano.

() É uma medida de inteligência de uma máquina, onde se a máquina pode se passar por um humano em uma conversa de texto, ela passa no teste.

Assinale a opção que indica a relação correta, segundo a ordem apresentada.

- a) 1 - 3 - 2 - 4.
- b) 1 - 2 - 4 - 3.
- c) 4 - 3 - 2 - 1.
- d) 3 - 2 - 1 - 4.

Comentários:

(1) Refere-se à IA fraca (1), que é especializada em tarefas específicas, como assistentes virtuais ou sistemas de recomendação;

(3) Define a IA generativa (3), que cria novos conteúdos como textos, imagens ou áudios com base em dados de treinamento;

(2) Refere-se à IA forte (2), uma forma hipotética de IA com inteligência geral comparável à humana;

(4) Trata-se do Teste de Turing (4), proposto por Alan Turing para avaliar se uma máquina consegue simular uma conversa humana.

Gabarito: Letra A

16.(FGV / Câmara dos Deputados - 2024) Em relação ao potencial de discriminação ilícita ou abusiva em sistemas de Inteligência Artificial (IA), assinale a afirmação mais precisa.

- a) Sistemas de IA são objetivos, imparciais e não realizam discriminações.
- b) A discriminação por sistemas de IA ocorre apenas quando há intenção explícita do programador.
- c) A IA pode inadvertidamente discriminar com base nos dados em que foi treinada.
- d) A legislação atual proíbe qualquer forma de IA que possa resultar em processos de discriminação, sejam eles de qualquer tipo.
- e) A discriminação em IA é um problema resolvido com tecnologias modernas de machine learning.

Comentários:

(a) Errado. IA não é "naturalmente" objetiva: pode reproduzir vieses e gerar discriminações a depender de dados, métricas e contexto de uso.

(b) Errado. Discriminação pode surgir sem intenção do programador, por vieses implícitos nos dados, variáveis proxy e decisões de modelagem.

- (c) Correto. Se o treinamento reflete desigualdades ou vieses históricos, o sistema pode aprender padrões discriminatórios e aplicá-los inadvertidamente.
- (d) Errado. A legislação tende a regular e mitigar riscos, não a proibir “qualquer IA” com potencial discriminatório de forma absoluta e genérica.
- (e) Errado. Técnicas modernas ajudam, mas não “resolvem” o tema: vieses podem persistir e exigem governança, auditoria e monitoramento contínuo.

Gabarito: Letra C

17.(FGV / Câmara dos Deputados - 2024) Em termos de regulamentação de Inteligência Artificial (IA), a seguinte estratégia é frequentemente considerada essencial para garantir a segurança e a ética nas relações:

- a) desenvolvimento de padrões internacionais, jurídicos e regulatórios, para a implementação de IA.
- b) regulamentação rigorosa e uniforme em todos os países acerca da aplicação de IA.
- c) banimento total do uso de IA em determinados setores, especialmente nas áreas da saúde, segurança e controle de acesso.
- d) deixar a regulamentação essencialmente com as empresas desenvolvedoras de IA, tendo em vista sua expertise na análise da tecnologia.
- e) priorizar a autorregulação regulada do setor pelas entidades desenvolvedoras de IA.

Comentários:

- (a) Correto. Padrões internacionais e marcos jurídicos/regulatórios harmonizam princípios (segurança, transparência, responsabilização) e orientam a implementação de IA, reduzindo riscos e assimetrias entre países.
- (b) Errado. Exigir rigor e uniformidade total em todos os países é pouco factível e desconsidera diferenças legais, culturais e de maturidade regulatória, dificultando a adoção coordenada.
- (c) Errado. Banimento total é medida extrema e pouco proporcional: tende a inviabilizar benefícios e não substitui governança baseada em risco, controles e fiscalização.
- (d) Errado. Deixar a regulação essencialmente com as empresas gera conflito de interesses e fragiliza a proteção do público, pois falta independência e mecanismos externos de accountability.
- (e) Errado. Autorregulação regulada pode complementar, mas não substitui padrões internacionais e normas jurídicas; sozinha, tende a ser insuficiente para garantir segurança e ética de forma ampla.

Gabarito: Letra A

18.(FGV / Câmara dos Deputados - 2024) No contexto jurídico brasileiro, assinale a afirmativa correta acerca do modo como a autonomia de um sistema de Inteligência Artificial (IA) é geralmente tratada, em questões relativas à sua responsabilidade por ações e atividades.

- a) A IA é considerada uma entidade legal autônoma com responsabilidades próprias, sendo um sujeito de direito.
- b) A responsabilidade pela IA e suas atividades é atribuída exclusivamente ao seu usuário final.
- c) A autonomia jurídica da IA não é reconhecida legalmente, recaindo a responsabilidade, como regra, sobre seus atos aos operadores humanos.
- d) Sistemas de IA têm, em algumas jurisdições, o mesmo status legal que incapazes.
- e) A lei considera a IA uma extensão do seu programador, devendo o mesmo ser legalmente acionado em todos os casos.

Comentários:

- (a) Errado. No Brasil, a IA não é tratada como sujeito de direito com personalidade jurídica própria; em regra, não se atribui a ela responsabilidade autônoma por seus atos.
- (b) Errado. A responsabilização não recai, de forma exclusiva e automática, apenas no usuário final; a análise costuma envolver quem opera, controla e se beneficia do sistema.
- (c) Correto. A autonomia jurídica da IA, em geral, não é reconhecida; assim, a responsabilidade por ações e atividades tende a recair sobre operadores humanos (usuários, fornecedores, gestores), conforme o caso.
- (d) Errado. Não há, no tratamento jurídico brasileiro, equiparação geral de IA ao status legal de incapazes; a discussão se concentra em imputação a pessoas naturais/jurídicas.
- (e) Errado. A IA não é vista como mera "extensão do programador" em todos os casos; a responsabilização não é automática e pode variar conforme participação, controle e deveres de cada agente.

Gabarito: Letra C

19.(FGV / Câmara dos Deputados - 2024) No contexto de proteção aos direitos da personalidade, assinale a afirmativa correta acerca do tratamento conferido pela legislação brasileira à representação visual de indivíduos por sistemas de Inteligência Artificial (IA).

- a) A IA tem permissão legal para replicar a personalidade de qualquer indivíduo, tendo em vista se tratar de simulação virtual.

- b) O uso de IA para replicar personalidades sem consentimento é amplamente permitido, por se tratar de ação virtual e sem impacto prático. Todavia, o uso comercial desta tecnologia encontra limites na legislação.
- c) Há leis específicas acerca da proteção dos direitos da personalidade e dos dados pessoais no Brasil, as quais também se aplicam no que couber às relações que envolvem Inteligências Artificiais.
- d) Apenas celebridades e pessoas notórias têm proteção legal contra replicação de personalidade por IA.
- e) Não existem ainda leis que abordem a tutela dos direitos da personalidade no ambiente virtual no Brasil.

Comentários:

- (a) Errado. A legislação tutela direitos da personalidade (imagem, honra, voz etc.) e não autoriza replicação irrestrita por IA só por ser "simulação".
- (b) Errado. A ausência de consentimento tende a violar direitos da personalidade; não é "amplamente permitido" por ser virtual, e os limites não se restringem ao uso comercial.
- (c) Correto. Há normas como o Código Civil (direitos da personalidade) e a LGPD (dados pessoais) que se aplicam, no que couber, a situações envolvendo IA.
- (d) Errado. A proteção dos direitos da personalidade é geral, não exclusiva de celebridades ou pessoas notórias.
- (e) Errado. O ordenamento já prevê tutela de direitos da personalidade e sua proteção também alcança o ambiente digital/virtual.

Gabarito: Letra C

20.(FGV / Câmara dos Deputados - 2024) Acerca do tratamento de dados pessoais por inteligência artificial (IA) e sua regulação no Brasil, assinale a afirmativa correta.

- a) A IA pode tratar dados sensíveis sem restrições, tendo em vista a ausência de interferência humana.
- b) A IA deve ser programada para seguir as leis de proteção de dados do país onde for utilizada e comercializada, independentemente do país de seu desenvolvimento e fabricação.

- c) As leis de proteção de dados não se aplicam a relações que envolvam IA, tendo em vista não ser ela agente de tratamento de dados, ou seja, pessoa natural ou jurídica que realiza tratamento de dados pessoais.
- d) A IA deve coletar o maior número de dados pessoais sem consentimento dos titulares, visando a melhorar seu próprio sistema.
- e) A IA deve seguir normas globais de proteção de dados, independente das peculiaridades da legislação local.

Comentários:

- (a) Errado. O tratamento de dados sensíveis é sujeito a bases legais e salvaguardas; o uso de IA não elimina restrições nem dispensa responsabilidade pelo tratamento.
- (b) Correto. A conformidade deve observar a legislação do país onde a IA é usada e ofertada, pois é nesse território que ocorre o tratamento e incidem as regras locais.
- (c) Errado. A existência de IA não afasta a aplicação das leis de proteção de dados; o tratamento continua vinculado a agentes responsáveis (controlador/operador) e às obrigações legais.
- (d) Errado. Coletar "o máximo" de dados sem consentimento contraria princípios e bases legais; melhoria de sistema não autoriza coleta indiscriminada de dados pessoais.
- (e) Errado. Normas globais podem orientar, mas não substituem a legislação local; a IA deve se adequar às exigências específicas do ordenamento do país de uso.

Gabarito: Letra B

LISTA DE QUESTÕES

- 1. (FGV / CNU - 2025) Em relação aos desafios presentes na relação entre Inteligência Artificial Generativa (IAG) e comunicação ética, analise as afirmativas a seguir.**

I. O uso de dados gerados por inteligência artificial deve cumprir as regulamentações vigentes, embora enfrente desafios impostos pelo rápido avanço tecnológico, que frequentemente supera a velocidade da elaboração legislativa.

II. O uso de dados gerados por inteligência artificial deve respeitar a privacidade e a proteção de dados, embora enfrente desafios para assegurar a defesa contra usos indevidos.

III. O uso de dados gerados por inteligência artificial deve se pautar na autonomia exercida pela própria IA em relação à supervisão humana, embora enfrente desafios para promover uma comunicação clara e eficiente.

Está correto o que se afirma em:

- a) I, apenas;
- b) I e II, apenas
- c) I e III, apenas;
- d) II e III, apenas;
- e) I, II e III.

- 2. (FGV / CNU - 2025) No setor público, as ferramentas de Inteligência Artificial Generativa (IAG) oferecem oportunidades para modernizar processos, como automação de tarefas repetitivas, redação de documentos e criação de materiais visuais. Contudo, sua implementação precisa de supervisão humana para que vieses ou informações imprecisas não sejam reproduzidos, especialmente em instituições públicas que lidam com informações sensíveis e de impacto social. A fase do ciclo de desenvolvimento de modelos de IAG na qual ocorre essa supervisão, com o ajuste e a captura de padrões nos dados, é a de:**

- a) aplicação;
- b) inferência;
- c) alucinação;
- d) implantação;
- e) treinamento.

- 3. (FGV / TCE-PE - 2025) Muitos cenários de análise de dados envolvem conjuntos sem rótulos disponíveis, como é comum em agrupamentos de clientes, detecção de padrões anômalos ou redução de dimensionalidade. Nesses casos, técnicas de aprendizado não supervisionado são essenciais para extrair conhecimento oculto nos dados.**

Com relação ao aprendizado não supervisionado em Machine Learning, assinale a afirmativa correta.

- a) O aprendizado não supervisionado depende de conjuntos de dados previamente rotulados para mapear entradas a saídas durante o treinamento.
- b) Técnicas de aprendizado não supervisionado, como árvores de decisão e regressão logística, são ideais para prever rótulos em problemas de classificação supervisionada.
- c) O aprendizado não supervisionado é utilizado para gerar automaticamente rótulos com base em padrões nos dados, sem necessidade de saídas conhecidas previamente.
- d) A principal limitação do aprendizado não supervisionado é que ele não consegue lidar com grandes volumes de dados, sendo restrito a pequenos conjuntos.
- e) O aprendizado não supervisionado só pode ser utilizado quando todos os atributos do conjunto de dados forem categóricos.

4. (FGV / TCE-PE - 2025) No campo da inteligência artificial, os agentes desempenham papel central como entidades capazes de perceber o ambiente, tomar decisões e agir com base em metas definidas. Compreender sua estrutura e tipos é fundamental para o desenvolvimento de sistemas inteligentes. Assinale a afirmativa que descreve corretamente uma característica de agentes de inteligência artificial.

- a) Um agente reativo simples armazena historicamente os estados anteriores do ambiente para prever ações futuras com base em aprendizado profundo.
- b) Agentes baseados em objetivos não consideram o estado atual do ambiente, mas tomam decisões aleatórias até alcançarem a meta desejada.
- c) Agentes baseados em utilidade avaliam diferentes cursos de ação e escolhem aquele que maximiza um valor numérico associado à satisfação da meta.
- d) Um agente só pode ser considerado inteligente se tiver consciência própria e habilidades linguísticas semelhantes às humanas.
- e) Agentes de IA operam exclusivamente em ambientes totalmente observáveis e determinísticos, pois exigem informações completas para funcionar.

5. (FGV / CNU - 2025) Martin está elaborando uma cartilha sobre o uso ético da Inteligência Artificial (IA) em seu setor, que atua no atendimento ao público. Para isso, a IA deve fornecer informações sobre as entradas, as saídas e o funcionamento do algoritmo utilizado, bem como a forma como cada parte contribui para o resultado final. Na cartilha de uso ético da IA de Martin, devem constar requisitos sobre:

- a) explicabilidade;
- b) hiperparametrização;

- c) aprendizado profundo;
- d) modelos largos de linguagem;
- e) processamento de linguagem natural.

6. (FGV / TCE-PE - 2025) Com relação aos Grandes Modelos de Linguagens (LLMs), avalie as afirmativas a seguir e assinale (V) para verdadeira e (F) para falsa.

() LLMs são capazes de fazer inferências a partir de um contexto, gerar respostas contextualmente relevantes, traduzir documentos para outros idiomas, resumir textos, responder a perguntas ou mesmo auxiliar em tarefas de redação criativa ou geração de código.

() Os LLMs representam um avanço considerável no processamento de linguagem natural (PNL) e tornaram-se facilmente acessíveis ao público por meio de interfaces como o Chat GPT-3 e o GPT-4. Outros exemplos de LLMs são os modelos Llama e as representações de codificadores bidirecionais, como BERT e RoBERTa.

() LLM é um modelo de aprendizado de máquina que pode ser usado na inteligência artificial generativa, capaz de executar diferentes funções. Os LLM são treinados a partir de grandes volumes de dados.

As afirmativas são, segundo a ordem apresentada,

- a) V - F - V.
- b) V - F - F.
- c) V - V - V.
- d) F - V - V.
- e) F - V - F.

7. (FGV / TCE-PE - 2025) Com o avanço do deep learning, redes neurais profundas e grandes modelos de linguagem (LLMs) vêm sendo amplamente utilizados em aplicações como tradução automática, geração de texto, reconhecimento de imagens e assistentes virtuais. A respeito de redes neurais profundas, deep learning e grandes modelos de linguagem (LLMs), assinale a afirmativa correta.

- a) Redes neurais profundas possuem apenas uma camada oculta entre a entrada e a saída e são ideais para tarefas simples de classificação linear.
- b) O termo deep learning refere-se a técnicas que dispensam o uso de redes neurais artificiais, utilizando apenas algoritmos estatísticos tradicionais.
- c) Os grandes modelos de linguagem (LLMs) são caracterizados por seu tamanho reduzido, pois dependem de poucos parâmetros para evitar sobrecarga computacional.

- d) Os grandes modelos de linguagem (LLMs) utilizam arquiteturas de redes neurais profundas, como os transformadores, para processar sequências de texto e aprender padrões complexos.
- e) Redes neurais profundas são indicadas exclusivamente para reconhecimento de imagens e não são aplicadas em processamento de linguagem natural.

8. (FGV / TCE-PE - 2025) Com a popularização de modelos de linguagem de grande escala (LLMs), como o GPT e o Claude, a engenharia de prompt tornou-se uma habilidade essencial para direcionar corretamente esses modelos, extraindo respostas mais úteis, seguras e alinhadas ao objetivo do usuário. Em relação às boas práticas de engenharia de prompt aplicadas a grandes modelos de linguagem (LLMs), assinale a afirmativa correta.

- a) A engenharia de prompt exige conhecimento profundo de linguagens de programação, pois os prompts devem ser escritos em linguagens formais como Python ou SQL.
- b) Prompts vagos e abertos tendem a melhorar a criatividade dos modelos e garantem maior precisão, especialmente em tarefas críticas e factuais.
- c) Instruções explícitas, exemplos no prompt e delimitação clara da tarefa aumentam a probabilidade de o LLM produzir respostas relevantes e adequadas ao objetivo.
- d) LLMs interpretam todos os prompts da mesma forma, independentemente da estrutura, do idioma ou da ordem em que as informações são fornecidas.
- e) A engenharia de prompt não tem impacto sobre a segurança das respostas geradas, já que os LLMs seguem regras internas fixas de filtragem de conteúdo.

9. (FGV / TCE-PE - 2025) Os grandes modelos de linguagem, também conhecidos como LLMs (Large Language Model),

- a) empregam uma tabela numérica para representar cada palavra, o que possibilita reconhecer relações entre palavras, como vocábulos com significados semelhantes.
- b) correspondem a um conjunto de redes neurais em que cada uma consiste em um codificador e um decodificador com recursos de recorrência e convoluções.
- c) processam entradas sequencialmente, o que potencializa a realização dos cálculos mais complexos.
- d) utilizam vetores multidimensionais, conhecidos como incorporações de palavras, para representá-las de modo que aquelas com significados contextuais semelhantes ou com outras relações fiquem próximas entre si no espaço vetorial.
- e) processam sequências inteiras em paralelo, empregando recursos de recorrência e convoluções, o que possibilita o uso extensivo de GPUs (Graphics Processing Units) para treinar LLMs.

10.(FGV / MACAEPREV - 2024) Large Language Models (LLMs) são um tipo de modelo IA projetado para lidar com tarefas de processamento de linguagem natural (PLN) em uma escala muito grande. Esses modelos são treinados com enormes quantidades de dados textuais e são capazes de entender e gerar texto em linguagem natural de forma altamente sofisticada. Em relação aos Large Language Models (LLMs), como o GPT, a abordagem mais relevante para melhorar a capacidade do modelo de gerar respostas coerentes e contextualmente apropriadas em conversas prolongadas, entre as listadas, é

- a) aumentar o número de parâmetros do modelo.
- b) utilizar a técnica de fine-tuning em um grande conjunto de dados não rotulados.
- c) implementar um mecanismo de atenção (Attention Mechanism).
- d) aplicar a tokenização BPE (Byte Pair Encoding) ao texto de entrada.
- e) aumentar a frequência de palavras raras no conjunto de treinamento.

11.(FGV / TCE-PA - 2024) O campo da inteligência artificial generativa é dedicado ao desenvolvimento de algoritmos capazes de gerar novas instâncias de dados. Suas aplicações incluem, por exemplo, a criação de textos, imagens, áudio e vídeo. As redes generativas adversárias (Generative Adversarial Networks - GANs) são um exemplo de IA generativa que possuem arquitetura baseada em duas redes, chamadas geradora e discriminadora, que competem entre si. Um dos principais problemas das GANs ocorre quando a rede geradora produz apenas uma quantidade limitada de tipos de dados, mesmo que seus dados de treinamento sejam mais ricos e diversificados. Isso ocorre porque a rede geradora consegue "enganar" a rede discriminadora mais facilmente quando dados daqueles tipos específicos são produzidos. A esse fenômeno dá-se o nome de

- a) Falha de Convergência (Convergence Failure).
- b) Sobreajuste (Overfitting).
- c) Colapso de Modo (Mode Collapse).
- d) Filtragem Estocástica (Stochastic Filtering).
- e) Crescimento de Padrões Frequentes (Frequent Pattern Growth).

12.(FGV / TCE-PA - 2024) O uso de Inteligência Artificial generativa é de grande utilidade para desenvolvedores web, por permitir a criação rápida de ilustrações e gráficos de alta qualidade. Por exemplo, uma das ferramentas mais populares atualmente é a aplicação Crayon, anteriormente conhecida como DALL-E mini, por ser uma ferramenta de acesso livre com interface amigável. No entanto, essas ferramentas podem frustrar os usuários por apresentarem limitações que inviabilizam o uso dos elementos visuais criados a partir de seus resultados. A respeito das tendências no uso de IA generativa em design web, avalie as afirmativas a seguir:

I. Há limitações éticas relacionadas à reprodução de potenciais vieses discriminatórios, provenientes das bases de dados de treinamento das redes generativas.

II. Sua principal vantagem consiste na eliminação de elementos de propriedade intelectual protegida nas imagens geradas, garantindo aos desenvolvedores a não-obrigatoriedade de pagamentos de direitos autorais.

III. Há preocupações com relação à geração de imagens extremamente realistas e com o potencial uso dos chamados "deepfakes" em campanhas de desinformação.

Está correto o que se afirma em

- a) I, apenas.
- b) I e II, apenas.
- c) I, II e III.
- d) II e III, apenas.
- e) I e III, apenas.

13.(FGV / Prefeitura de Caraguatatuba - SP - 2024) Considere as seguintes afirmativas sobre Inteligência Artificial, assinale V para a afirmativa verdadeira e F para a falsa.

() A Inteligência Artificial é uma tecnologia disruptiva que tem o potencial de mudar o mundo.

() A Inteligência Artificial é utilizada em diversas aplicações práticas, como carros autônomos, assistentes virtuais e sistemas de recomendação.

() A Inteligência Artificial não apresenta riscos éticos, pois é uma ferramenta que pode ser usada para o bem ou para o mal, dependendo das intenções de seus usuários.

As afirmativas são, respectivamente,

- a) V - F - F.
- b) V - V - V.
- c) F - V - V.
- d) V - F - V.
- e) V - V - F.

14.(FGV / EPE - 2024) Há uma família de modelos de IA generativa que tem dois modelos treinados em conjunto: o gerador e o discriminador. O gerador tenta criar dados falsos que sejam indistinguíveis dos dados reais, enquanto que o discriminador tenta distinguir entre dados reais e falsos. O treinamento é um jogo min-max, em que o gerador melhora suas habilidades para enganar o discriminador, e o discriminador melhora suas habilidades para detectar dados falsos. Assinale a opção que apresenta as características do modelo de IA generativa descritas no texto.

- a) Generative Adversarial Networks.
- b) Variational Autoencoders.
- c) Energy-Based Models.
- d) Autoregressive Models.
- e) Normalizing Flow Models.

15.(FGV / CGM de Belo Horizonte - MG - 2024) Relacione os termos de Inteligência Artificial (IA) às suas respectivas definições.

- 1. IA fraca**
- 2. IA forte**
- 3. IA generativa**
- 4. Teste de Turing**

() É capaz de resolver uma única tarefa, pode automatizar tarefas demoradas e analisar dados de maneiras que os humanos às vezes não podem.

() É uma categoria de algoritmos de IA que gera novos resultados com base nos dados em que foram treinados.

() É capaz de resolver uma gama extensa e arbitrária de tarefas, incluindo aquelas que são novas, e executá-las com eficácia comparável à de um ser humano.

() É uma medida de inteligência de uma máquina, onde se a máquina pode se passar por um humano em uma conversa de texto, ela passa no teste.

Assinale a opção que indica a relação correta, segundo a ordem apresentada.

- a) 1 - 3 - 2 - 4.
- b) 1 - 2 - 4 - 3.
- c) 4 - 3 - 2 - 1.
- d) 3 - 2 - 1 - 4.

16.(FGV / Câmara dos Deputados - 2024) Em relação ao potencial de discriminação ilícita ou abusiva em sistemas de Inteligência Artificial (IA), assinale a afirmação mais precisa.

- a) Sistemas de IA são objetivos, imparciais e não realizam discriminações.
- b) A discriminação por sistemas de IA ocorre apenas quando há intenção explícita do programador.
- c) A IA pode inadvertidamente discriminar com base nos dados em que foi treinada.
- d) A legislação atual proíbe qualquer forma de IA que possa resultar em processos de discriminação, sejam eles de qualquer tipo.
- e) A discriminação em IA é um problema resolvido com tecnologias modernas de machine learning.

17.(FGV / Câmara dos Deputados - 2024) Em termos de regulamentação de Inteligência Artificial (IA), a seguinte estratégia é frequentemente considerada essencial para garantir a segurança e a ética nas relações:

- a) desenvolvimento de padrões internacionais, jurídicos e regulatórios, para a implementação de IA.
- b) regulamentação rigorosa e uniforme em todos os países acerca da aplicação de IA.
- c) banimento total do uso de IA em determinados setores, especialmente nas áreas da saúde, segurança e controle de acesso.
- d) deixar a regulamentação essencialmente com as empresas desenvolvedoras de IA, tendo em vista sua expertise na análise da tecnologia.
- e) priorizar a autorregulação regulada do setor pelas entidades desenvolvedoras de IA.

18.(FGV / Câmara dos Deputados - 2024) No contexto jurídico brasileiro, assinale a afirmativa correta acerca do modo como a autonomia de um sistema de Inteligência Artificial (IA) é geralmente tratada, em questões relativas à sua responsabilidade por ações e atividades.

- a) A IA é considerada uma entidade legal autônoma com responsabilidades próprias, sendo um sujeito de direito.
- b) A responsabilidade pela IA e suas atividades é atribuída exclusivamente ao seu usuário final.
- c) A autonomia jurídica da IA não é reconhecida legalmente, recaindo a responsabilidade, como regra, sobre seus atos aos operadores humanos.
- d) Sistemas de IA têm, em algumas jurisdições, o mesmo status legal que incapazes.
- e) A lei considera a IA uma extensão do seu programador, devendo o mesmo ser legalmente acionado em todos os casos.

19.(FGV / Câmara dos Deputados - 2024) No contexto de proteção aos direitos da personalidade, assinale a afirmativa correta acerca do tratamento conferido pela legislação brasileira à representação visual de indivíduos por sistemas de Inteligência Artificial (IA).

- a) A IA tem permissão legal para replicar a personalidade de qualquer indivíduo, tendo em vista se tratar de simulação virtual.
- b) O uso de IA para replicar personalidades sem consentimento é amplamente permitido, por se tratar de ação virtual e sem impacto prático. Todavia, o uso comercial desta tecnologia encontra limites na legislação.
- c) Há leis específicas acerca da proteção dos direitos da personalidade e dos dados pessoais no Brasil, as quais também se aplicam no que couber às relações que envolvem Inteligências Artificiais.

- d) Apenas celebridades e pessoas notórias têm proteção legal contra replicação de personalidade por IA.
- e) Não existem ainda leis que abordem a tutela dos direitos da personalidade no ambiente virtual no Brasil.

20.(FGV / Câmara dos Deputados - 2024) Acerca do tratamento de dados pessoais por inteligência artificial (IA) e sua regulação no Brasil, assinale a afirmativa correta.

- a) A IA pode tratar dados sensíveis sem restrições, tendo em vista a ausência de interferência humana.
- b) A IA deve ser programada para seguir as leis de proteção de dados do país onde for utilizada e comercializada, independentemente do país de seu desenvolvimento e fabricação.
- c) As leis de proteção de dados não se aplicam a relações que envolvam IA, tendo em vista não ser ela agente de tratamento de dados, ou seja, pessoa natural ou jurídica que realiza tratamento de dados pessoais.
- d) A IA deve coletar o maior número de dados pessoais sem consentimento dos titulares, visando a melhorar seu próprio sistema.
- e) A IA deve seguir normas globais de proteção de dados, independente das peculiaridades da legislação local.

GABARITO

1. LETRA B
2. LETRA E
3. LETRA C
4. LETRA C
5. LETRA A
6. LETRA C
7. LETRA D
8. LETRA C
9. LETRA D
10. LETRA C
11. LETRA C
12. LETRA E
13. LETRA E
14. LETRA A
15. LETRA A
16. LETRA C
17. LETRA A
18. LETRA C
19. LETRA C
20. LETRA B

NOÇÕES DE MACHINE LEARNING


Conceitos Básicos

INCIDÊNCIA EM PROVA: MÉDIA

MACHINE LEARNING (APRENDIZADO DE MÁQUINA)

Trata-se de um subcampo da Inteligência Artificial que se dedica ao desenvolvimento de algoritmos capazes de aprender padrões a partir de dados e tomar decisões ou fazer previsões sem serem explicitamente programados para cada tarefa. Em vez de regras fixas, o sistema ajusta seus modelos com base em exemplos, melhorando seu desempenho ao longo do tempo. É amplamente utilizado em aplicações como recomendação de produtos, reconhecimento de imagem, detecção de fraudes e processamento de linguagem natural.

A inteligência artificial surgiu em meados da década de 1950; o aprendizado de máquina começa a ser estudado no início da década de 1980; e a última década foi marcada pelo aprendizado profundo (Deep Learning). *E como eles se diferenciam?* Ora, a inteligência artificial trata de programas que podem sentir, raciocinar, agir e se adaptar a fim de imitar a inteligência humana por meio de diversas técnicas – sendo o aprendizado de máquina uma delas.



Já o aprendizado de máquina trata de algoritmos cujo desempenho melhoram à medida que eles são expostos a mais dados no decorrer do tempo. Por fim, o aprendizado profundo é um subconjunto do aprendizado de máquina em que um software é capaz de treinar a si mesmo para executar diversas tarefas por meio da utilização de redes neurais para aprender algo a partir de uma quantidade massiva de dados. O foco dessa aula é especificamente Aprendizado de Máquina!

O Aprendizado de Máquina (*Machine Learning*) é a ciência e a arte de programar computadores para que eles possam aprender com os dados. Uma definição um pouco mais formal diria que se trata do campo de estudo que dá aos computadores a capacidade de aprender sem ser explicitamente programado. Eu gosto mais dessa segunda definição porque ela traz uma comparação entre algoritmo de programação tradicional e algoritmo de aprendizado de máquina.



O que é a programação tradicional? Trata-se do processo manual de escrever um conjunto de regras em uma sequência de passos - também chamado de algoritmo - utilizando uma linguagem de programação para que o computador as execute sobre um conjunto de dados de entrada a fim de produzir um conjunto de resultados de saída. Imaginem um software que recebe um conjunto de nomes de alunos e suas respectivas notas em uma prova e retorna um ranking de notas.

Os dados de entrada são nome/nota dos alunos; as regras são escritas por um programador capaz de entender o problema e decompô-lo em passos que um computador entenda utilizando uma linguagem de programação; e o resultado será o ranking de notas. *Simples, não?* Ocorre que, para alguns casos, essa abordagem apresenta diversos problemas. Imaginem um software que recebe uma imagem de entrada qualquer e identifica se há um gato nela ou não. É bem complexo...

Humanos conseguem fazer isso em frações de segundos, mas uma máquina teria bem mais dificuldades. Utilizando a programação tradicional, teríamos diversos gargalos: em primeiro lugar, seria necessário ter um ou mais programadores; em segundo lugar, não basta que ele entenda de programação, ele também deve entender do problema e sugerir uma maneira de resolvê-lo. Ora, criar um conjunto de passos para identificar um gato em uma imagem não é uma tarefa simples...



Uma forma de tentar resolver esse problema é por meio do aprendizado de máquina. Ocorre que ele funciona de uma maneira praticamente inversa à programação tradicional. Nós continuamos entrando com dados, mas - em vez de um programador criar manualmente as regras - são inseridos exemplos de resultados passados. Já a saída de um algoritmo de aprendizado de máquina são justamente as regras. Note que as entidades mudaram de lugar...



No caso do software identificador de gatos, nós continuaríamos inserindo imagens de entrada quaisquer, mas também seriam inseridos diversos exemplos de resultados (isto é, imagens que efetivamente contêm gatos). A saída do algoritmo de aprendizado de máquina seria capaz, por si só, de realizar um mapeamento estatístico entre os dados de entrada e os exemplos de resultados esperados a fim descobrir se há ou não um gato em uma imagem. Em vez de um programador dizer quais são as regras, quem diz é o algoritmo! Diz se não é genial...

Em outras palavras, o algoritmo de aprendizado de máquina consegue extrair regras de identificação de gatos por meio de padrões estatísticos comuns entre os dados de entrada e os resultados esperados. *Professor, isso significa que o algoritmo de aprendizado de máquina retornará um código-fonte?* Não, pessoal... são regras estatísticas na forma de um modelo matemático - composto de diversas funções e parâmetros - capaz de identificar padrões a partir de exemplos.

Vocês notaram que as áreas de tecnologia de informação estatística começaram a despencar em concurso público recentemente? Pois é, esse é um dos grandes motivos - existe um relacionamento íntimo entre essas áreas no contexto de aprendizado de máquina. Voltando: quanto mais exemplos de resultados você oferece, mais o algoritmo é treinado, mais regras são aprendidas e mais ajustado se torna o modelo. Essa etapa do processo de aprendizado de máquina é chamada de **Treinamento**.



Trata-se de uma etapa custosa porque idealmente nós temos que inserir quantidades massivas de exemplos de resultados para que o modelo fique o mais ajustado possível. Após essa fase, nós temos a etapa de **Inferência**, que é bem menos custosa. Ela ocorre quando utilizamos uma programação bem próxima à programação tradicional com regras aprendidas na etapa anterior e novos dados para gerar inferir resultados.

O cientista de dados será responsável pela etapa de treinamento a fim de gerar regras aprendidas e outros softwares as utilizam como entrada e com novos dados para processar e gerar novos resultados. *Vocês se lembram do exemplo do gato?* Após o cientista de dados treinar o algoritmos e chegar a um conjunto de regras (modelo), outros softwares podem utilizar esse modelo na programação clássica para inferir se uma imagem possui ou não um gato.

É claaaaaro que nem tudo é perfeito! *Lembra da estatística?* Pois é, a inferência é probabilística e, não, determinística. Isso significa que ela identificará uma alta ou uma baixa probabilidade de ter um gato em uma imagem - ela não vai cravar que existe ou não um gato em uma imagem. *Querem um exemplo?* As quatro imagens a seguir possuem um gato! Ora, se nós temos dificuldades, imaginem uma máquina...

Veja que a máquina não funciona tão diferente dos humanos: nós só sabemos o que é um gato porque já vimos vários exemplos de gatos e de não-gatos. Dessa forma, nosso cérebro consegue abstrair e generalizar o que seria um gato. Agora se fizéssemos esse experimento quando nós fôssemos bem

pequenos, nós provavelmente não saberíamos diferenciar porque ainda não fomos bem treinados com vários exemplos e não-exemplos.

Vocês viram a grande utilidade do aprendizado de máquina? Em algumas situações, é extremamente difícil criar regras. Se fôssemos criar um algoritmo utilizando apenas a programação tradicional para identificar gatos em uma imagem, provavelmente teríamos que contratar zoólogos/biólogos - além dos programadores. O aprendizado de máquina supre esse gargalo, não sendo necessária a atuação de zoólogos/biólogos - a máquina aprenderá apenas por meio de dados de treinamento.

MACHINE LEARNING

SUBCAMPO DA INTELIGÊNCIA ARTIFICIAL QUE FORNECE AOS COMPUTADORES A HABILIDADE DE APRENDER SEM SEREM EXPLICITAMENTE PROGRAMADOS

PROCESSO EM QUE O DESEMPENHO DE UMA TAREFA AUMENTA COM A EXPERIÊNCIA EXTRAÍDA DE NOVOS DADOS

A MÁQUINA PODE APRENDER A PARTIR DE SEUS ERROS E FAZER INFERÊNCIAS SOBRE DADOS

DIFERE-SE DA PROGRAMAÇÃO TRADICIONAL POR GERAR REGRAS A PARTIR DE RESULTADOS E, NÃO, O CONTRÁRIO

MODELOS SÃO REGRAS ESTATÍSTICAS NA FORMA DE MODELOS MATEMÁTICOS E PARÂMETROS

A ETAPA DE TREINAMENTO É MAIS CUSTOSA E A ETAPA DE INFERÊNCIA É MENOS CUSTOSA

Tipos de Aprendizado

RELEVÂNCIA EM PROVA: ALTÍSSIMA

As aplicações da aprendizagem de máquina são amplas e incluem desde jogos e detecção de fraudes até análise da bolsa de valores. É utilizada em sistemas de recomendação, como os da Netflix e Spotify, que sugerem conteúdos com base no histórico dos usuários, bem como em mecanismos que agrupam notícias semelhantes. Também serve para categorizar automaticamente páginas web por tema e identificar e-mails como spam. Suas aplicações são diversas e em constante expansão, sendo baseadas em diferentes abordagens algorítmicas, classificadas conforme seus métodos específicos.

Aprendizado Supervisionado

APRENDIZADO SUPERVISIONADO

Tipo de aprendizado de máquina em que o modelo é treinado com um conjunto de dados rotulados, ou seja, cada entrada possui uma saída correta conhecida. O objetivo é aprender uma função que mapeie entradas para saídas, permitindo prever resultados para novos dados. É utilizado em problemas de classificação (como identificar se um e-mail é spam) e regressão (como prever preços), sendo um dos paradigmas mais comuns e eficazes em aplicações práticas.

O Aprendizado Supervisionado é uma das abordagens centrais da aprendizagem de máquina (machine learning), em que o modelo é treinado a partir de dados rotulados. Isso significa que o algoritmo recebe como entrada um conjunto de exemplos nos quais cada exemplo é composto por uma entrada (também chamada de features) e uma saída esperada (o rótulo ou label). O objetivo do modelo é aprender uma

função que relacione entradas e saídas, de modo que, ao receber novas entradas, consiga prever a saída correta com boa precisão.


Durante o treinamento, o algoritmo ajusta seus parâmetros internos com base nos erros que comete nas previsões. Ele utiliza métricas de erro – como erro quadrático médio ou entropia cruzada, dependendo do tipo de problema – para medir o quão longe suas previsões estão dos rótulos reais. Com isso, o modelo vai refinando seu comportamento até atingir um desempenho aceitável. Esse processo pode envolver técnicas como regressão, redes neurais, máquinas de vetor de suporte (SVM), árvores de decisão, entre outras.

Existem dois grandes tipos de problemas de aprendizado supervisionado: classificação e regressão. Na classificação, o objetivo é prever categorias discretas, como "spam" ou "não spam", "positivo" ou "negativo". Já na regressão, a saída é contínua, como prever a temperatura de amanhã ou o valor de uma casa. Ambas as tarefas compartilham a estrutura básica de aprendizado supervisionado, mas diferem no tipo de função que o modelo tenta aprender.

Uma etapa fundamental do processo é a divisão dos dados em conjuntos de treinamento e teste (e às vezes também validação). O modelo aprende com o conjunto de treinamento e é avaliado com o conjunto de teste, o que permite verificar sua capacidade de generalizar – isto é, aplicar o que aprendeu a dados nunca vistos antes. Um modelo que memoriza os dados de treinamento sem aprender padrões generalizáveis está sofrendo de overfitting (sobreajuste).

O sucesso do aprendizado supervisionado depende fortemente da qualidade e quantidade dos dados rotulados. Ter muitos exemplos variados e bem rotulados aumenta a chance de o modelo aprender padrões úteis e generalizáveis. No entanto, em muitos contextos práticos, rotular dados pode ser caro e demorado, o que limita a aplicação dessa abordagem. Isso tem levado ao interesse crescente por métodos como aprendizado semi-supervisionado e aprendizado não supervisionado, que requerem menos dados rotulados.

Em suma: o aprendizado supervisionado é uma abordagem de aprendizado de máquina em que um supervisor já conhece de antemão o resultado (rótulo/classe) e pode guiar o aprendizado mapeando as entradas em saídas por meio do ajuste de parâmetros em um modelo capaz de prever rótulos desconhecidos. Por fim, é interessante saber que os problemas de aprendizado supervisionado geralmente tratam de uma variável quantitativa ou qualitativa.



Se os rótulos se referem a um conjunto infinito de valores numéricos contínuos (Ex: $> R\$100,00$ ou $< R\$100,00$), a tarefa se chama regressão. Já se os rótulos se referem a um conjunto finito e não ordenado de valores categóricos (Ex: Alto ou Baixo), a tarefa se chama classificação. Os modelos supervisionados mais conhecidos são: árvores de decisão, regressão linear, regressão logística, redes neurais, K-Nearest Neighbors (KNN), Support Vector Machines (SVM), etc.

Aprendizado Não-Supervisionado

APRENDIZADO NÃO SUPERVISIONADO

Tipo de aprendizado de máquina que ocorre quando o modelo recebe apenas dados de entrada, sem rótulos associados, e precisa identificar padrões, estruturas ou agrupamentos por conta própria. O objetivo é explorar a organização dos dados, como segmentar clientes em grupos semelhantes ou reduzir dimensionalidade. Técnicas como clustering e análise de componentes principais são exemplos desse tipo de aprendizado, muito útil em cenários exploratórios e de descoberta de conhecimento.

O Aprendizado Não Supervisionado é um ramo da aprendizagem de máquina em que os algoritmos analisam dados sem rótulos pré-definidos. Ao contrário do aprendizado supervisionado, onde cada exemplo de treino possui uma resposta esperada (rótulo), aqui o modelo tenta descobrir padrões, estruturas ou agrupamentos nos dados por conta própria. O objetivo é revelar a organização interna dos dados ou representações úteis, sem qualquer orientação explícita sobre o que deve ser aprendido.

Entre as tarefas mais comuns do aprendizado não supervisionado estão a clusterização (agrupamento) e a redução de dimensionalidade. A clusterização consiste em identificar grupos de dados que possuem características semelhantes, sendo útil em contextos como segmentação de clientes, agrupamento de documentos e organização de imagens. Já a redução de dimensionalidade busca representar os dados em um espaço com menos variáveis, facilitando visualizações e tornando modelos mais eficientes, como no caso do PCA (Análise de Componentes Principais).

O aprendizado não supervisionado é especialmente útil quando não há rótulos disponíveis, o que ocorre frequentemente no mundo real, onde rotular grandes quantidades de dados pode ser caro, demorado ou até mesmo inviável. Por isso, ele é uma ferramenta poderosa para exploração de dados, permitindo que analistas compreendam melhor conjuntos complexos antes de aplicar métodos mais específicos ou supervisionados. Ele também é amplamente utilizado como passo prévio em pipelines de processamento de dados.

Uma das dificuldades centrais desse tipo de aprendizado é avaliar a qualidade dos resultados, uma vez que não há um rótulo "correto" com o qual comparar. Por exemplo, ao agrupar dados, como saber se os grupos formados são "bons"? Para isso, usam-se métricas internas como silhouette score, ou validação humana e conhecimento de domínio. Essa ambiguidade na validação é um dos principais desafios para seu uso sistemático em aplicações críticas.

Algoritmos comuns de aprendizado não supervisionado incluem o K-Means, para agrupamento por proximidade; o DBSCAN, que detecta agrupamentos de densidade; e técnicas de redução como PCA ou t-SNE, muito usadas em visualização de dados. Redes neurais autoencoders também são uma forma poderosa de aprendizado não supervisionado, pois aprendem representações comprimidas dos dados sem precisar de rótulos.

Em síntese, o aprendizado não supervisionado é uma abordagem essencial na ciência de dados e na inteligência artificial, especialmente útil para revelar estruturas ocultas em dados brutos. Embora seus resultados possam ser mais difíceis de interpretar ou avaliar do que no aprendizado supervisionado, sua capacidade de funcionar sem dados rotulados o torna uma ferramenta indispensável para exploração e organização de grandes volumes de informação.

Aprendizado Semi-Supervisionado

APRENDIZADO SEMI-SUPERVISIONADO

Tipo de aprendizado de máquina que combina as características dos aprendizados supervisionado e não supervisionado, utilizando uma pequena quantidade de dados rotulados junto com uma grande quantidade de dados não rotulados. O modelo aproveita a estrutura dos dados não rotulados para melhorar seu desempenho, reduzindo a necessidade de rotulação manual, que pode ser cara ou demorada. É especialmente útil em áreas como visão computacional e processamento de linguagem natural, onde há muitos dados disponíveis, mas poucos rotulados.

Trata-se de um meio termo entre o aprendizado supervisionado e o não-supervisionado. Nesse caso, utilizamos dados rotulados e não-rotulados para o treinamento. Em geral, utiliza-se uma pequena quantidade de dados rotulados e uma grande quantidade de dados não-rotulados, visto que dados não rotulados são mais baratos e são obtidos com menos esforço. Ela pode ser aplicada para o agrupamento, regras de associação, classificação ou regressão. É isso, aqui não tem segredo!

Aprendizado Por Reforço

APRENDIZADO POR REFORÇO

Tipo de aprendizado de máquina baseado na interação de um agente com um ambiente, no qual ele aprende a tomar decisões por meio de tentativas e erros, recebendo recompensas ou penalidades. O objetivo é maximizar a recompensa acumulada ao longo do tempo, aprendendo uma política de ações eficiente. Esse paradigma é comum em jogos, robótica e sistemas de controle, sendo conhecido por aplicações como algoritmos que aprendem a jogar xadrez ou dirigir veículos autônomos.

Trata-se de um conjunto de técnicas que utilizam tentativa e erro para descobrir decisões ótimas de como interagir com ambiente ou com outros agentes. Ele tem como meta reforçar ou recompensar uma ação considerada positiva e punir uma ação considerada negativa. Um exemplo são os famosos robôs aspiradores! Esses robôs percorre os cômodos de uma casa, identifica obstáculos e armazena quais rotas funcionam melhor para limpar a casa.

Ele literalmente constrói um mapa da casa e refina/atualiza esse mapa a cada nova limpeza. Se ele tenta um determinado percurso e encontra um obstáculo, ele pune essa ação considerada negativa não fazendo mais esse percurso; se ele tenta um determinado percurso e não encontra um obstáculo, ele reforça essa ação considerada positiva fazendo novamente esse percurso da próxima vez. É claro que no começo ele erra bastante, mas depois ele acerta...

No fim das contas, algoritmos de aprendizado por reforço baseiam-se em reforço positivo/negativo para otimização de resultado. No caso dos robôs aspiradores, eles punem a passagem por trechos pouco promissores e recompensam a passagem por trechos mais promissores. É uma técnica bem menos empregada e que eu particularmente nunca vi cair em prova, mas não custa nada mencionar em aula porque sempre pode cair.

QUESTÕES COMENTADAS – MACHINE LEARNING

1. (FAFIPA / Prefeitura de Paranavaí - PR - 2025) Uma das principais técnicas usadas na Inteligência Artificial é conhecida como aprendizado não supervisionado. Assinale a alternativa que melhor descreve o que é o aprendizado não supervisionado.

- a) Abordagem, onde o algoritmo identifica padrões ou estruturas em dados não rotulados, sem orientação prévia.
- b) Método que utiliza recompensas e penalidades para otimizar decisões em ambientes dinâmicos.
- c) Sistema que combina redes neurais profundas para processar linguagem natural.
- d) Processo de treinamento exclusivo para tarefas de visão computacional com supervisão humana.
- e) Técnica, em que o modelo é treinado com dados rotulados para prever resultados específicos.

Comentários:

- (a) Correto. No aprendizado não supervisionado, os dados não possuem rótulos e o objetivo é descobrir padrões, agrupamentos ou estruturas subjacentes automaticamente pelo algoritmo;
- (b) Errado. Esse é o conceito de aprendizado por reforço, que se baseia em recompensas e penalidades para tomada de decisões sequenciais;
- (c) Errado. Essa descrição está relacionada ao uso de deep learning para NLP, mas não define o aprendizado não supervisionado;
- (d) Errado. A supervisão humana indica um processo supervisionado, e o foco em visão computacional é apenas uma aplicação específica;
- (e) Errado. A utilização de dados rotulados caracteriza o aprendizado supervisionado, e não o não supervisionado.

Gabarito: Letra A

2. (CEBRASPE / CAESB-DF - 2025) Assinale a opção em que é citada a ciência do desenvolvimento de algoritmos e modelos estatísticos utilizados por sistemas de computador para a realização de tarefas sem instruções explícitas, baseando-se em padrões e inferências, de modo que um sistema aprenda e melhore automaticamente e com base na experiência.

- a) internet of things
- b) generative AI
- c) big data
- d) machine learning
- e) cloud computing

Comentários:

- (a) Errado. Internet of Things (IoT) refere-se à interconexão de dispositivos físicos à internet, não ao desenvolvimento de algoritmos que aprendem com a experiência;
- (b) Errado. A IA generativa se refere à criação de conteúdo (texto, imagem, etc.), geralmente com base em aprendizado de máquina, mas não define a ciência do aprendizado em si;
- (c) Errado. Big Data trata do processamento e análise de grandes volumes de dados, mas não necessariamente envolve aprendizado autônomo;
- (d) Correto. Machine Learning é a área da ciência da computação que desenvolve algoritmos capazes de aprender a partir de dados, melhorando seu desempenho com a experiência sem serem explicitamente programados;
- (e) Errado. Cloud Computing é a oferta de serviços de computação pela internet, como armazenamento e processamento, mas não está diretamente ligada à criação de algoritmos que aprendem com dados.

Gabarito: Letra D

3. (IADES / CNEN - 2025) No que concerne ao uso da inteligência artificial na organização da informação, assinale a alternativa correta.

- a) As técnicas de Machine Learning, advindas da inteligência artificial, estão trazendo grandes contribuições para os estudos de Big data.
- b) O uso de algoritmos nos mecanismos de busca da internet ainda é incipiente.
- c) A inteligência artificial precisa de um volume de dados estruturados e homogêneos para extrair seus resultados.
- d) As redes neurais não supervisionadas são as mais adequadas para a organização da informação.
- e) O impacto das redes neurais na recuperação da informação é pequeno.

Comentários:

- (a) Correto. Técnicas de Machine Learning têm sido essenciais para lidar com os grandes volumes de dados (Big Data), permitindo organizar, classificar e extrair padrões de forma automatizada e eficiente;
- (b) Errado. O uso de algoritmos em mecanismos de busca está bastante avançado, sendo a base de funcionamento de sistemas como o Google, que utilizam IA para entregar resultados relevantes;
- (c) Errado. A IA pode trabalhar com dados estruturados e não estruturados, e é justamente sua flexibilidade que permite atuar em diversos tipos de informação;
- (d) Errado. A escolha entre redes supervisionadas ou não supervisionadas depende do problema. A organização da informação geralmente se beneficia de técnicas supervisionadas com dados rotulados;

(e) Errado. As redes neurais têm impacto significativo na recuperação da informação, melhorando buscas, recomendações e classificação de conteúdos.

Gabarito: Letra A

4. (CEBRASPE / EMBRAPA - 2025) Acerca de inteligência artificial e machine learning, julgue o item que se segue.

O aprendizado não supervisionado se caracteriza pela utilização de dados previamente rotulados para treinar um modelo de machine learning, permitindo que ele aprenda padrões automaticamente a partir dos rótulos desses dados.

Comentários:

O enunciado descreve características do aprendizado supervisionado, e não do não supervisionado. No aprendizado não supervisionado, os dados não possuem rótulos, e o modelo identifica padrões ocultos por conta própria, como em agrupamentos ou redução de dimensionalidade.

Gabarito: Errado

5. (Instituto Ágata / Prefeitura de Anajás - PA - 2024) No contexto do aprendizado de máquina, um modelo supervisionado é um modelo que

- a) necessita de dados não rotulados para realizar o treinamento.
- b) supervisiona o treinamento das redes neurais para evitar a ocorrência de mínimos locais.
- c) também pode ser classificado como modelo de análise associativa.
- d) necessita de dados rotulados para realizar o treinamento.
- e) supervisiona o treinamento das redes neurais para evitar a ocorrência de mínimos globais.

Comentários:

(a) Errado. Modelos supervisionados exigem dados rotulados, ou seja, com entradas e saídas conhecidas. Dados não rotulados são usados em aprendizado não supervisionado;

(b) Errado. A supervisão em "aprendizado supervisionado" não se refere à atuação sobre mínimos locais ou globais, mas sim à presença de rótulos nos dados de treino;

(c) Errado. Modelos de análise associativa são típicos do aprendizado não supervisionado, como em regras de associação (ex: market basket analysis);

(d) Correto. O aprendizado supervisionado requer dados rotulados, ou seja, exemplos com a resposta esperada, para que o modelo aprenda a mapear entradas para saídas;

(e) Errado. A supervisão aqui não diz respeito ao controle de mínimos globais, e sim à estrutura dos dados usados no treinamento (rotulados ou não).

Gabarito: Letra D

6. (CEBRASPE / EMBRAPA - 2025) Acerca de inteligência artificial e machine learning, julgue o item que se segue.

Diferentemente do aprendizado supervisionado e não supervisionado, o aprendizado por reforço baseia-se em um agente que interage com um ambiente e recebe recompensas ou penalidades conforme suas ações, buscando maximizar um retorno cumulativo ao longo do tempo.

Comentários:

O aprendizado por reforço é um tipo de machine learning no qual um agente toma decisões em um ambiente, recebendo recompensas ou penalidades com base em suas ações. O objetivo é maximizar o retorno cumulativo ao longo do tempo, aprendendo por tentativa e erro.

Gabarito: Correto

7. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, relativo à ciência de dados.

O aprendizado de máquina não supervisionado utiliza algoritmos para analisar conjuntos de dados não rotulados, a fim de descobrir padrões ocultos sem necessidade de intervenção humana.

Comentários:

O aprendizado de máquina não supervisionado aplica algoritmos em dados não rotulados para identificar padrões, agrupamentos ou estruturas ocultas nos dados, sem a necessidade de intervenção humana direta ou rótulos prévios.

Gabarito: Correto

8. (CEBRASPE / ANM - 2025) Julgue o item a seguir, referente a sistema operacional, edição de planilhas, organização e segurança da informação, redes de computadores e inteligência artificial.

O aprendizado supervisionado analisa dados sem respostas predefinidas, identificando padrões ou categorias de forma autônoma, sem orientações específicas.

Comentários:

O que foi descrito no enunciado é uma característica do aprendizado não supervisionado. Já o aprendizado supervisionado utiliza dados rotulados (com respostas predefinidas) para treinar modelos que aprendem a associar entradas a saídas específicas.

Gabarito: Errado

9. (CEBRASPE / ANM - 2025) Julgue o item a seguir, referente ao Microsoft Office 365, a redes de computadores, à segurança da informação e à inteligência artificial.

Aprendizado de máquina (machine learning) é o processo de treinar um modelo para identificar padrões e fazer previsões ou gerar novos conteúdos com base nas informações processadas.

Comentários:

Aprendizado de máquina (machine learning) é, de fato, o processo no qual um modelo é treinado com dados para identificar padrões, fazer previsões e, em alguns casos (como na IA generativa), produzir novos conteúdos com base no que foi aprendido durante o treinamento.

Gabarito: Correto

10.(IBEC / Prefeitura de Tremedal - BA - 2025) Qual é o papel de algoritmos de aprendizado de máquina na análise de dados avançada?

- a) Substituir a análise manual ao identificar padrões complexos e fazer previsões baseadas em grandes volumes de dados.
- b) Armazenar dados em bancos de dados relacionais para consultas mais rápidas.
- c) Criar visualizações interativas, como gráficos e dashboards.
- d) Garantir a segurança dos dados contra-ataques cibernéticos.
- e) Automatizar o backup de dados em servidores de nuvem.

Comentários:

(a) Correto. Algoritmos de aprendizado de máquina são essenciais na análise de dados avançada, pois conseguem identificar padrões complexos e realizar previsões com base em grandes volumes de dados, substituindo ou complementando análises manuais;

(b) Errado. Armazenar dados em bancos relacionais é tarefa de sistemas de gerenciamento de banco de dados (SGBDs), não de aprendizado de máquina;

(c) Errado. Visualizações interativas são criadas com ferramentas de BI (Business Intelligence), como Power BI ou Tableau, e não são o foco dos algoritmos de ML;

(d) Errado. A segurança contra ataques cibernéticos está mais ligada à cibersegurança, não ao aprendizado de máquina diretamente;

(e) Errado. O backup de dados em nuvem é uma função de infraestrutura de TI, não de análise ou aprendizado de dados.

Gabarito: Letra A

11.(IGEDUC / Prefeitura de Cupira - PE - 2024) Algoritmos de aprendizado de máquina podem ser supervisionados, não supervisionados ou semi-supervisionados, permitindo que sistemas sejam treinados com ou sem conjuntos de dados rotulados, dependendo do objetivo do modelo.

Comentários:

Algoritmos de aprendizado de máquina podem ser classificados em supervisionados (usam dados rotulados), não supervisionados (trabalham com dados sem rótulos) e semi-supervisionados (combinam ambos). Essa flexibilidade permite escolher o tipo de aprendizado mais adequado ao objetivo do modelo e à disponibilidade de dados.

Gabarito: Correto

12.(IGEDUC / Prefeitura de Cupira - PE - 2024) O aprendizado por reforço é uma técnica de inteligência artificial que utiliza recompensas e punições para treinar modelos, possibilitando que agentes de IA aprendam a tomar decisões com base em interações com o ambiente.

Comentários:

O aprendizado por reforço é um tipo de inteligência artificial em que um agente aprende a tomar decisões ao interagir com um ambiente, recebendo recompensas por ações corretas e punições por ações inadequadas, com o objetivo de maximizar o retorno cumulativo ao longo do tempo.

Gabarito: Correto

13.(FGV / TCE-GO - 2024) Os modelos de aprendizado de máquina desempenham um papel fundamental na análise e interpretação de dados em uma variedade de domínios. Uma característica dos modelos de aprendizado de máquina supervisionados e não supervisionados é que modelos supervisionados

- a) exploram a detecção de outliers, enquanto modelos não supervisionados usam dados representados em formatos como XML ou JSON para treinamento.
- b) geralmente têm menos tendência ao overfitting do que modelos não supervisionados.
- c) requerem dados rotulados para treinamento, enquanto modelos não supervisionados podem funcionar com dados não rotulados.
- d) são mais adequados para tarefas de análise exploratória de dados, enquanto modelos não supervisionados são mais adequados para previsão de séries temporais.

e) são usados apenas para classificação, enquanto modelos não supervisionados são usados apenas para agrupamento.

Comentários:

(a) Errado. A detecção de outliers pode ser feita por ambos os tipos de modelos. O uso de formatos como XML ou JSON é relacionado ao armazenamento de dados, não ao tipo de aprendizado;

(b) Errado. Modelos supervisionados podem, inclusive, ser mais propensos ao overfitting, especialmente quando os dados de treinamento são limitados;

(c) Correto. A principal distinção é que o aprendizado supervisionado requer dados rotulados (com entradas e saídas conhecidas), enquanto o aprendizado não supervisionado utiliza dados não rotulados para identificar padrões ocultos;

(d) Errado. Análise exploratória é mais comum em aprendizado não supervisionado. Já a previsão de séries temporais costuma utilizar aprendizado supervisionado com dados históricos rotulados;

(e) Errado. O aprendizado supervisionado não é restrito à classificação – também abrange regressão. Da mesma forma, aprendizado não supervisionado não é exclusivo para agrupamento.

Gabarito: Letra C

14.(Quadrix / CRMV-SE - 2024) Assinale a alternativa que apresenta a principal diferença entre aprendizado supervisionado e aprendizado não supervisionado em aprendizado de máquina.

a) Aprendizado supervisionado e não supervisionado são termos intercambiáveis, sem diferenças significativas.

b) O aprendizado supervisionado requer um conjunto de dados de treinamento rotulado, enquanto o aprendizado não supervisionado não utiliza rótulos.

c) No aprendizado supervisionado, os modelos são treinados sem um conjunto de dados específico, enquanto no aprendizado não supervisionado, um conjunto de dados de treinamento é obrigatório.

d) O aprendizado supervisionado é utilizado apenas para classificação, enquanto o aprendizado não supervisionado é aplicado apenas em problemas de regressão.

e) O aprendizado supervisionado e não supervisionado são conceitos desatualizados e não mais são relevantes em aprendizado de máquina moderno.

Comentários:

(a) Errado. Aprendizado supervisionado e não supervisionado não são intercambiáveis – tratam de abordagens distintas com finalidades diferentes;

- (b) Correto. A principal diferença é que o aprendizado supervisionado utiliza dados rotulados (com entrada e saída conhecida), enquanto o não supervisionado trabalha com dados não rotulados, buscando identificar padrões ou estruturas ocultas;
- (c) Errado. No aprendizado supervisionado, o modelo precisa de um conjunto de dados rotulado específico. A afirmação está invertida e incorreta;
- (d) Errado. O aprendizado supervisionado é usado tanto para classificação quanto para regressão. Já o aprendizado não supervisionado é usado para agrupamento (clustering), redução de dimensionalidade, entre outros – não para regressão supervisionada;
- (e) Errado. Os conceitos de aprendizado supervisionado e não supervisionado são fundamentais e amplamente utilizados no aprendizado de máquina atual.

Gabarito: Letra B

15.(CEBRASPE / MPO - 2024) Julgue o item a seguir, a respeito de conceitos de inteligência artificial.

O aprendizado supervisionado é definido pelo uso de conjuntos de dados rotulados para treinar algoritmos que classificam dados ou preveem resultados com precisão.

Comentários:

O aprendizado supervisionado utiliza conjuntos de dados rotulados (com entradas e saídas conhecidas) para treinar algoritmos capazes de classificar dados ou prever resultados com base em novos dados. Essa abordagem é amplamente usada em tarefas como reconhecimento de voz, diagnóstico médico e previsão de vendas.

Gabarito: Correto

16.(QUADRIX / CRQ - 12ª Região (GO, TO e DF) - 2024) Acerca dos tipos de computadores, do Microsoft Word 2016 e do aprendizado de máquina, julgue o item.

O aprendizado de máquina pode ser definido como uma técnica de ciência de dados que permite que os computadores usem os dados existentes para prever futuros comportamentos, resultados e tendências.

Comentários:

O aprendizado de máquina (machine learning) é, de fato, uma técnica da ciência de dados que capacita computadores a analisar dados existentes e, com base neles, fazer previsões sobre comportamentos, resultados e tendências futuras. Essa abordagem é amplamente utilizada em áreas como marketing, finanças, saúde e recomendação de conteúdo.

Gabarito: Correto

17. (IV - UFG / Câmara de Anápolis - GO - 2024) A Inteligência Artificial (IA) é uma ferramenta computacional que permitiu o avanço em diferentes áreas, entre elas: a saúde, finanças, marketing, entre outras. A principal ajuda, veio no apoio à tomada de decisões. As características que descrevem o aprendizado de máquina (machine learning) são

- a) compostas de algoritmos e modelos estatísticos que permitem que os sistemas aprendam a partir dos dados, usando identificação de padrões e fazendo previsões.
- b) baseadas em regras e conhecimentos para tomar decisões e fornecer soluções em um domínio específico, com total eficácia simulando o raciocínio humano.
- c) baseadas na autonomia, sem intervenção humana e demandam alto processamento computacional.
- d) baseadas em símbolos, regras que representam, manipulam e aprendem com interferências lógicas, usada na solução de problemas complexos.

Comentários:

- (a) Correto. O aprendizado de máquina (machine learning) utiliza algoritmos e modelos estatísticos que permitem aos sistemas aprender a partir dos dados, identificar padrões e fazer previsões, sem serem explicitamente programados para cada tarefa;
- (b) Errado. Essa descrição se refere aos sistemas especialistas, que funcionam com regras fixas e não aprendem com os dados;
- (c) Errado. Embora o ML possa reduzir a intervenção humana, ele requer supervisão na preparação dos dados, escolha de modelos e validação, e nem sempre demanda alto processamento – isso depende do tipo de algoritmo e volume de dados;
- (d) Errado. A descrição está mais alinhada à IA simbólica ou baseada em lógica, que não representa o núcleo do machine learning, que é orientado por dados e estatísticas, e não por regras fixas.

Gabarito: Letra A

18.(CEBRASPE / CTI - 2024) Julgue o próximo item, relativo a aprendizado de máquina.

No aprendizado de máquinas, o aprendizado supervisionado compreende um conjunto de dados de treinamento para ensinar modelos a mostrar a saída desejada.

Comentários:

No aprendizado supervisionado, os modelos são treinados com um conjunto de dados rotulado, ou seja, com exemplos que incluem entradas e as saídas desejadas. O objetivo é fazer com que o modelo aprenda

a mapear corretamente as entradas para as saídas, permitindo que ele generalize e faça previsões sobre novos dados.

Gabarito: Correto

19.(CEBRASPE / CTI - 2024) Julgue o próximo item, relativo a aprendizado de máquina.

Aprendizado de máquina pode ser definido como a criação e o uso de modelos que são aprendidos a partir dos dados.

Comentários:

Aprendizado de máquina (machine learning) é, de fato, a área da inteligência artificial que se dedica à criação e uso de modelos computacionais capazes de aprender automaticamente a partir de dados, identificando padrões e realizando previsões ou decisões sem serem explicitamente programados para cada tarefa.

Gabarito: Correto

20.(QUADRIX / CRM-TO - 2023) No que se refere às novas tecnologias, julgue o item.

O aprendizado de máquina é um subcampo da IA que se concentra no desenvolvimento de algoritmos e modelos que permitem aos sistemas aprenderem com os dados e melhorarem suas decisões ao longo do tempo, ajustando seu desempenho com base no feedback recebido.

Comentários:

O aprendizado de máquina (machine learning) é um subcampo da inteligência artificial (IA) focado no desenvolvimento de algoritmos e modelos capazes de aprender com dados, melhorar seu desempenho ao longo do tempo e ajustar suas decisões com base no feedback recebido. Isso permite que os sistemas se tornem mais precisos e eficientes sem reprogramação explícita.

Gabarito: Correto

71. (QUADRIX / CRM-MG - 2023) O tipo de aprendizagem de máquina que se baseia em dados preparados para treinamento, quando se sabe o desfecho de cada registro do conjunto de dados, em geral previamente rotulados por um especialista, é a aprendizagem

- a) supervisionada.
- b) não supervisionada.
- c) por reforço.
- d) aleatória.
- e) flexível.

Comentários:

- (a) Correto. A aprendizagem supervisionada utiliza dados rotulados, ou seja, dados de entrada associados a uma saída conhecida (o desfecho). Isso permite que o modelo aprenda a fazer previsões ou classificações com base nesses exemplos. Os rótulos geralmente são fornecidos por especialistas;
- (b) Errado. A aprendizagem não supervisionada trabalha com dados não rotulados, buscando identificar padrões ou estruturas nos dados sem conhecimento prévio das saídas;
- (c) Errado. A aprendizagem por reforço envolve um agente que aprende por meio de recompensas e penalidades, com base em interações com o ambiente, e não em dados rotulados;
- (d) Errado. "Aprendizagem aleatória" não é um tipo reconhecido de aprendizado de máquina;
- (e) Errado. "Aprendizagem flexível" não é um termo técnico utilizado em machine learning.

Gabarito: Letra A

21.(IBADE / SEA-SC - 2022) O processo pelo qual os computadores desenvolvem o reconhecimento de padrões, ou a capacidade de aprender continuamente, ou fazer previsões com base em dados, e então, fazer ajustes sem serem especificamente programados para isso, é chamado:

- a) Machine learning.
- b) Auto-Adjust.
- c) Business Intelligence.
- d) Systems Intelligence.
- e) Smart.

Comentários:

- (a) Correto. O processo descrito corresponde ao Machine Learning (aprendizado de máquina), que permite aos computadores reconhecer padrões, aprender com dados, fazer previsões e ajustar seu desempenho automaticamente, sem serem explicitamente programados para cada tarefa;
- (b) Errado. "Auto-Adjust" não é um termo técnico reconhecido na área de IA ou ciência de dados;
- (c) Errado. Business Intelligence refere-se à análise de dados para suporte à decisão, mas não envolve necessariamente aprendizado automático ou predição adaptativa;
- (d) Errado. "Systems Intelligence" não é um termo amplamente utilizado no contexto técnico da IA;
- (e) Errado. "Smart" é um adjetivo genérico e não define o processo técnico de aprendizado com dados.

Gabarito: Letra A

22.(CEBRASPE / MPO - 2024) Acerca de inteligência artificial, julgue o próximo item.

Pode-se utilizar machine learning, capaz de reconhecer e reproduzir padrões de inteligência artificial com base em experiência prévia, para um mecanismo de busca na Internet que funcione de forma automatizada.

Comentários:

O machine learning pode ser utilizado para desenvolver mecanismos de busca na Internet que reconhecem padrões de comportamento dos usuários e dados disponíveis, aprendendo com experiências prévias para oferecer resultados mais relevantes de forma automatizada.

Gabarito: Correto

LISTA DE QUESTÕES – MACHINE LEARNING

1. (FAFIPA / Prefeitura de Paranavaí - PR - 2025) Uma das principais técnicas usadas na Inteligência Artificial é conhecida como aprendizado não supervisionado. Assinale a alternativa que melhor descreve o que é o aprendizado não supervisionado.

- a) Abordagem, onde o algoritmo identifica padrões ou estruturas em dados não rotulados, sem orientação prévia.
- b) Método que utiliza recompensas e penalidades para otimizar decisões em ambientes dinâmicos.
- c) Sistema que combina redes neurais profundas para processar linguagem natural.
- d) Processo de treinamento exclusivo para tarefas de visão computacional com supervisão humana.
- e) Técnica, em que o modelo é treinado com dados rotulados para prever resultados específicos.

2. (CEBRASPE / CAESB-DF - 2025) Assinale a opção em que é citada a ciência do desenvolvimento de algoritmos e modelos estatísticos utilizados por sistemas de computador para a realização de tarefas sem instruções explícitas, baseando-se em padrões e inferências, de modo que um sistema aprenda e melhore automaticamente e com base na experiência.

- a) internet of things
- b) generative AI
- c) big data
- d) machine learning
- e) cloud computing

3. (IADES / CNEN - 2025) No que concerne ao uso da inteligência artificial na organização da informação, assinale a alternativa correta.

- a) As técnicas de Machine Learning, advindas da inteligência artificial, estão trazendo grandes contribuições para os estudos de Big data.
- b) O uso de algoritmos nos mecanismos de busca da internet ainda é incipiente.
- c) A inteligência artificial precisa de um volume de dados estruturados e homogêneos para extrair seus resultados.
- d) As redes neurais não supervisionadas são as mais adequadas para a organização da informação.
- e) O impacto das redes neurais na recuperação da informação é pequeno.

4. (CEBRASPE / EMBRAPA - 2025) Acerca de inteligência artificial e machine learning, julgue o item que se segue.

O aprendizado não supervisionado se caracteriza pela utilização de dados previamente rotulados para treinar um modelo de machine learning, permitindo que ele aprenda padrões automaticamente a partir dos rótulos desses dados.

5. (Instituto Ágata / Prefeitura de Anajás - PA - 2024) No contexto do aprendizado de máquina, um modelo supervisionado é um modelo que

- a) necessita de dados não rotulados para realizar o treinamento.
- b) supervisiona o treinamento das redes neurais para evitar a ocorrência de mínimos locais.
- c) também pode ser classificado como modelo de análise associativa.
- d) necessita de dados rotulados para realizar o treinamento.
- e) supervisiona o treinamento das redes neurais para evitar a ocorrência de mínimos globais.

6. (CEBRASPE / EMBRAPA - 2025) Acerca de inteligência artificial e machine learning, julgue o item que se segue.

Diferentemente do aprendizado supervisionado e não supervisionado, o aprendizado por reforço baseia-se em um agente que interage com um ambiente e recebe recompensas ou penalidades conforme suas ações, buscando maximizar um retorno cumulativo ao longo do tempo.

7. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, relativo à ciência de dados.

O aprendizado de máquina não supervisionado utiliza algoritmos para analisar conjuntos de dados não rotulados, a fim de descobrir padrões ocultos sem necessidade de intervenção humana.

8. (CEBRASPE / ANM - 2025) Julgue o item a seguir, referente a sistema operacional, edição de planilhas, organização e segurança da informação, redes de computadores e inteligência artificial.

O aprendizado supervisionado analisa dados sem respostas predefinidas, identificando padrões ou categorias de forma autônoma, sem orientações específicas.

9. (CEBRASPE / ANM - 2025) Julgue o item a seguir, referente ao Microsoft Office 365, a redes de computadores, à segurança da informação e à inteligência artificial.

Aprendizado de máquina (machine learning) é o processo de treinar um modelo para identificar padrões e fazer previsões ou gerar novos conteúdos com base nas informações processadas.

10.(IBEC / Prefeitura de Tremedal - BA - 2025) Qual é o papel de algoritmos de aprendizado de máquina na análise de dados avançada?

- a) Substituir a análise manual ao identificar padrões complexos e fazer previsões baseadas em grandes volumes de dados.
- b) Armazenar dados em bancos de dados relacionais para consultas mais rápidas.
- c) Criar visualizações interativas, como gráficos e dashboards.
- d) Garantir a segurança dos dados contra-ataques cibernéticos.
- e) Automatizar o backup de dados em servidores de nuvem.

11.(IGEDUC / Prefeitura de Cupira - PE - 2024) Algoritmos de aprendizado de máquina podem ser supervisionados, não supervisionados ou semi-supervisionados, permitindo que sistemas

sejam treinados com ou sem conjuntos de dados rotulados, dependendo do objetivo do modelo.

12.(IGEDUC / Prefeitura de Cupira - PE - 2024) O aprendizado por reforço é uma técnica de inteligência artificial que utiliza recompensas e punições para treinar modelos, possibilitando que agentes de IA aprendam a tomar decisões com base em interações com o ambiente.

13.(FGV / TCE-GO - 2024) Os modelos de aprendizado de máquina desempenham um papel fundamental na análise e interpretação de dados em uma variedade de domínios. Uma característica dos modelos de aprendizado de máquina supervisionados e não supervisionados é que modelos supervisionados

- a) exploram a detecção de outliers, enquanto modelos não supervisionados usam dados representados em formatos como XML ou JSON para treinamento.
- b) geralmente têm menos tendência ao overfitting do que modelos não supervisionados.
- c) requerem dados rotulados para treinamento, enquanto modelos não supervisionados podem funcionar com dados não rotulados.
- d) são mais adequados para tarefas de análise exploratória de dados, enquanto modelos não supervisionados são mais adequados para previsão de séries temporais.
- e) são usados apenas para classificação, enquanto modelos não supervisionados são usados apenas para agrupamento.

14.(Quadrix / CRMV-SE - 2024) Assinale a alternativa que apresenta a principal diferença entre aprendizado supervisionado e aprendizado não supervisionado em aprendizado de máquina.

- a) Aprendizado supervisionado e não supervisionado são termos intercambiáveis, sem diferenças significativas.
- b) O aprendizado supervisionado requer um conjunto de dados de treinamento rotulado, enquanto o aprendizado não supervisionado não utiliza rótulos.
- c) No aprendizado supervisionado, os modelos são treinados sem um conjunto de dados específico, enquanto no aprendizado não supervisionado, um conjunto de dados de treinamento é obrigatório.
- d) O aprendizado supervisionado é utilizado apenas para classificação, enquanto o aprendizado não supervisionado é aplicado apenas em problemas de regressão.
- e) O aprendizado supervisionado e não supervisionado são conceitos desatualizados e não mais são relevantes em aprendizado de máquina moderno.

15.(CEBRASPE / MPO - 2024) Julgue o item a seguir, a respeito de conceitos de inteligência artificial.

O aprendizado supervisionado é definido pelo uso de conjuntos de dados rotulados para treinar algoritmos que classificam dados ou preveem resultados com precisão.

16.(QUADRIX / CRQ - 12ª Região (GO, TO e DF) - 2024) Acerca dos tipos de computadores, do Microsoft Word 2016 e do aprendizado de máquina, julgue o item.

O aprendizado de máquina pode ser definido como uma técnica de ciência de dados que permite que os computadores usem os dados existentes para prever futuros comportamentos, resultados e tendências.

17. (IV - UFG / Câmara de Anápolis - GO - 2024) A Inteligência Artificial (IA) é uma ferramenta computacional que permitiu o avanço em diferentes áreas, entre elas: a saúde, finanças, marketing, entre outras. A principal ajuda, veio no apoio à tomada de decisões. As características que descrevem o aprendizado de máquina (machine learning) são

- a) compostas de algoritmos e modelos estatísticos que permitem que os sistemas aprendam a partir dos dados, usando identificação de padrões e fazendo previsões.
- b) baseadas em regras e conhecimentos para tomar decisões e fornecer soluções em um domínio específico, com total eficácia simulando o raciocínio humano.
- c) baseadas na autonomia, sem intervenção humana e demandam alto processamento computacional.
- d) baseadas em símbolos, regras que representam, manipulam e aprendem com interferências lógicas, usada na solução de problemas complexos.

18.(CEBRASPE / CTI - 2024) Julgue o próximo item, relativo a aprendizado de máquina.

No aprendizado de máquinas, o aprendizado supervisionado compreende um conjunto de dados de treinamento para ensinar modelos a mostrar a saída desejada.

19.(CEBRASPE / CTI - 2024) Julgue o próximo item, relativo a aprendizado de máquina.

Aprendizado de máquina pode ser definido como a criação e o uso de modelos que são aprendidos a partir dos dados.

20.(QUADRIX / CRM-TO - 2023) No que se refere às novas tecnologias, julgue o item.

O aprendizado de máquina é um subcampo da IA que se concentra no desenvolvimento de algoritmos e modelos que permitem aos sistemas aprenderem com os dados e melhorarem suas decisões ao longo do tempo, ajustando seu desempenho com base no feedback recebido.

21.(QUADRIX / CRM-MG - 2023) O tipo de aprendizagem de máquina que se baseia em dados preparados para treinamento, quando se sabe o desfecho de cada registro do conjunto de dados, em geral previamente rotulados por um especialista, é a aprendizagem

- a) supervisionada.
- b) não supervisionada.

- c) por reforço.
- d) aleatória.
- e) flexível.

22.(IBADE / SEA-SC - 2022) O processo pelo qual os computadores desenvolvem o reconhecimento de padrões, ou a capacidade de aprender continuamente, ou fazer previsões com base em dados, e então, fazer ajustes sem serem especificamente programados para isso, é chamado:

- a) Machine learning.
- b) Auto-Adjust.
- c) Business Intelligence.
- d) Systems Intelligence.
- e) Smart.

23.(CEBRASPE / MPO - 2024) Acerca de inteligência artificial, julgue o próximo item.

Pode-se utilizar machine learning, capaz de reconhecer e reproduzir padrões de inteligência artificial com base em experiência prévia, para um mecanismo de busca na Internet que funcione de forma automatizada.

GABARITO

1. LETRA A
2. LETRA D
3. LETRA A
4. ERRADO
5. LETRA D
6. CORRETO
7. CORRETO
8. ERRADO
9. CORRETO
10. LETRA A
11. CORRETO
12. CORRETO
13. LETRA C
14. LETRA B
15. CORRETO
16. CORRETO
17. LETRA A
18. CORRETO
19. CORRETO
20. CORRETO
21. LETRA A
22. LETRA A
23. CORRETO

ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.